

第 1 章 生成式人工智能概述

生成式人工智能正在改变人类获取知识、处理信息和开展科研工作的方式。对于研究新生而言，人工智能（Artificial Intelligence，AI）不再只是计算机科学中的专业概念，而是逐渐成为文献阅读、学术写作、数据分析、程序开发和研究管理中的重要工具。理解生成式人工智能的基本原理、能力边界和使用风险，是正确使用这类工具的前提。本章将从人工智能的发展脉络出发，介绍生成式人工智能的基本概念、大语言模型的工作机制、常见模型生态，以及智能体等新兴应用形态，帮助读者建立面向科研场景的人工智能基础认知。

1.1 AI 技术的发展

20 世纪中叶，人工智能研究开始从设想走向科学实践。科学家们尝试用符号逻辑、数学推理和程序规则来模拟人类的思维过程，希望让机器完成判断、推理、学习和问题求解等任务。此后，人工智能的发展经历了多次起伏：既有早期研究者对“机器智能”的高度期待，也有因技术瓶颈和应用效果不及预期而出现的“AI 寒冬”；既有基于规则的专家系统，也有后来模仿神经元连接方式的神经网络方法。

1.1.1 机器能思考吗？

1. 图灵测试：一场关于“模仿”的游戏

回顾这段历史，一个重要起点常被追溯到 1950 年。英国数学家艾伦·图灵（Alan Turing）在论文中提出了一个极具启发性的问题：“机器能思考吗？”这一问题不仅开启了人类对机器智能的系统讨论，也为后来人工智能学科的形成奠定了思想基础。从这个问题出发，人工智能逐渐发展为一门融合计算机科学、数学、认知科学与工程技术的交叉学科，并在今天深刻影响着科研、教育、产业和社会生活的方方面面。

图灵深知，“思考”这个词太抽象了，就像问“潜水艇会游泳吗”一样，很容易陷入无休止的哲学争论。于是，他天才般地把这个问题转化成了一个可操作的实验——“模仿游戏”，也就是后世闻名的图灵测试。图灵测试原理示意图如图 1-1 所示。为了理解这个测试的精髓，图灵设计了一个被墙壁隔开的三个房间。

房间 A（裁判）：坐着一位人类询问者。他的任务是不停地提问，试图分辨谁是人，谁是机器。

房间 B（人类）：坐着一位普通人，他在尽力证明自己是人类。

房间 C（机器）：放置着一台试图伪装成人的计算机。

在这个实验中，裁判 A 看不见 B 和 C，只能通过键盘和屏幕与他们进行纯文字聊天。

这就屏蔽了外貌、声音等干扰，强迫裁判只通过“语言交流的内容”来判断对方的身份。



图 1-1 图灵测试原理示意图

图 1-1 揭示了图灵测试的核心逻辑——“混淆”。如果计算机 C 能够通过巧妙的回答，撒谎、讲笑话甚至故意犯错，让裁判 A 误以为它就是那个真人（房间 B），且误判率超过 30%，那么图灵认为：这台机器就通过了测试，拥有了智能。这张图告诉大家，AI 最初的定义是“功能主义”的——人不在乎机器脑袋里有没有灵魂，只要它表现得像人，它就是智能的。

2. 达特茅斯会议：AI 的诞生

图灵播下了火种，但直到 6 年后，“人工智能”这门学科才真正有了名字。让目光转向 1956 年的夏天，地点是美国新罕布什尔州的汉诺威小镇。1956 年达特茅斯会议的核心人物如图 1-2 所示。这些人就是 AI 领域最早的科学家，包括提出“人工智能”概念的约翰·麦卡锡（John McCarthy）、神经网络先驱马文·闵斯基（Marvin Minsky）等。

这群开创者在会议提案中，给出了 AI 的初始定义，他们自信地写道：“学习的每一个方面或智能的任何特征，原则上都可以被精确描述，以至于可以制造一台机器来模拟它。”当时的学者们天真地认为，只需一个夏天和一台早期的电子管计算机，就能解决机器视觉和自然语言理解的问题。这种盲目的乐观虽然在后来遭遇现实的骨感，导致了漫长的“AI 寒冬”，但也确立了符号主义长达 30 年的主导地位。




图 1-2 1956 年达特茅斯会议的核心人物

1.1.2 符号主义的兴衰

达特茅斯会议之后，人工智能迎来了它的第一波黄金时代。在长达 30 年的时间里，一种被称为“符号主义”的学术范式主导了整个领域。这一派别的核心信仰既迷人又极具雄心：他们认为人类的智慧本质上就是一套精密复杂的逻辑运算，只要人类能将世间万物的运行规律抽象为一套标准的“符号”，并预设好完美的“逻辑规则”，机器就能通过类似于数学推导的方式，产生出媲美人类的智能。这种“自上而下”的设计理念，试图用人类写就的百科全书式规则来穷尽世界的奥秘，将计算机变成一个永远不会出错的理性思考者。

1. 巅峰时刻：深蓝的暴力美学

符号主义范式下最辉煌的瞬间，莫过于 1997 年那场震惊世界的“人机大战”。当时，IBM 公司研发的超级计算机“深蓝”（Deep Blue）正面挑战人类国际象棋的最高峰——世界冠军卡斯帕罗夫。1997 年“人机大战”深蓝对战卡斯帕罗夫如图 1-3 所示。

正如图 1-3 所展示的那样，画面中卡斯帕罗夫双手抱头、眉头紧锁的痛苦神情，与对面冷静冰冷的机器形成了极其强烈的对比。这场胜利被誉为符号主义的“暴力美学”巅峰：深蓝并没有像人类棋手那样去“感悟”棋局，它背后的核心是人类大师输入的数百万个开局库规则，以及每秒能计算 2 亿步棋的恐怖算力。

图 1-3 深刻揭示了符号主义的本质——“穷举”。只要博弈的规则是确定的、边界是清晰的，机器就能凭借其超高的逻辑严密性和计算速度，在人类引以为傲的智力领域实现“超车”。那一刻，人们仿佛看到了一条通往通用人工智能的康庄大道：只要规则足够多、算力足够强，机器似乎就能解决一切问题。然而，这种基于“写死规则”的乐观，很快就在现实世界的复杂性面前撞上了坚硬的南墙。



图 1-3 1997 年“人机大战”：深蓝对战卡斯帕罗夫

2. 致命缺陷：波兰尼悖论

然而，这种依靠“人工撰写规则”的辉煌并没有持续太久。当科学家们试图让机器走出棋盘，去处理现实生活中的简单任务（如识别一张照片、理解一句笑话）时，符号主义很快就撞上了无法逾越的南墙。人们沮丧地发现，现实世界并非由非黑即白的逻辑组成，绝大多数人类智慧是无法被写成清晰规则的。为了直观理解这种范式的崩溃，通过引入认知科学中著名的“波兰尼悖论（Polanyi's Paradox）”来进行解释。波兰尼悖论：“为什么规则无法定义一只猫？”如图 1-4 所示。该图生动地展现了人类直觉与机器逻辑之间那道深不可测的鸿沟。




图 1-4 波兰尼悖论：为什么规则无法定义一只猫？

左侧是人类的“直觉视界”：画面中是一张普通的橘猫照片。作为人类，你认出它只需 0.1 秒，这个过程如呼吸般自然，甚至不需要任何推理。正如哲学家迈克尔·波兰尼所言：“我们所知道的，远比我们能说出来的要多。”这种瞬间捕获本质的能力，被称为“隐性知识”。

右侧是机器的“逻辑陷阱”：画面中展现了程序员试图为“猫”编写的逻辑代码。为了让机

器认出这只猫，开发者必须穷尽所有特征：如果耳朵是三角形， $\{\cdot\cdot\cdot\}$ ；如果有胡须， $\{\cdot\cdot\cdot\}$ 。

图 1-4 的视觉冲突精准地击中了符号主义的死穴：现实是流动的、模糊的，而规则是僵硬的、孤立的。在现实场景中，当左边的猫调皮地转过头去，三角形的耳朵消失了；或者画面中出现的是一只没有胡须的流浪猫，或者是一只耳朵下垂的折耳猫——右侧那套看似严密的代码逻辑就会在瞬间“瘫痪”并报出错误。符号主义者试图用有限的 If-Then 语句去网罗无限的现实世界，这无异于痴人说梦。人类自己都无法精确描述出“认出一只猫”的所有细微判别准则，又怎么可能将其翻译成完美的指令喂给计算机呢？这种“只可意会，不可言传”的困境，成为了 AI 发展史上的第一次重大瓶颈，也迫使科学家们开始反思：与其教机器“背规则”，不如教机器像生物一样去“学规律”。

1.1.3 连接主义的复兴

当符号主义者在“穷举规则”的死胡同里撞得头破血流时，另一群科学家提出了一个完全相反的构想：既然人无法像上帝一样写出智能的全部规则，为什么不模仿自然界最成功的案例——人类大脑？

这种“自下而上”的路径被称为“连接主义”。它的核心哲学非常简洁：智能不应是由人类“写”进去的指令，而应是机器从海量数据中自我“学”出来的联系。连接主义者不再执着于复杂的逻辑推导，而是试图在计算机中构建一种模仿大脑神经元互联结构的数学模型。

1. 核心理念：模仿生物神经元

为了理解这是如何实现的，这里对比一下人脑和人工神经网络模型的结构。生物神经元与人工神经元的对比如图 1-5 所示。该图是理解现代深度学习的钥匙，它展示了数学家是如何抽象生物结构的：

图 1-5 (a) 生物神经网络展示了大脑的基本单位——神经元。你可以看到树突像繁茂的树枝一样张开，时刻捕捉周围传输来的微弱信号；轴突则像长长的光纤，负责将处理后的指令发射出去；而连接点突触则是智慧的精髓，它通过化学物质调节信号的强弱。

图 1-5 (b) 人工神经网络是人工智能学者模仿生物构造画出来的数学模型。从宏观上看，它由输入层、隐藏层、输出层横向排列构成；而从微观的运算机制来看，它通过以下三个核心组件实现了对生物神经元功能的数字化模拟：

(1) 输入：对应生物神经元的树突。如图中输入层的节点 (x_1, x_2, x_3) ，它们负责“吞噬”原始数据（例如一张照片中被拆解后的像素特征）。图中特别标注的“+1”节点被称为“偏置项”，它像是一个调节底噪的旋钮，确保模型具有更高的灵活性。

(2) 权重：这是连接主义的灵魂，对应生物学中的突触强度。图中节点之间密集的连接

线，尤其是那些加粗的红色箭头，代表了信号传递的强弱。所谓“学习”的过程，本质上就是在大脑或算法被海量数据“冲刷”时，不断微调这些连线的粗细（权重数值），使得有用的连接变得强壮，无用的连接逐渐萎缩。




图 1-5 生物神经元与人工神经元的对比

(3) 激活函数：模仿神经元的放电阈值。图中隐藏层的节点 (a_1, a_2, a_3) (a 即代表 激活) 承担了这一任务。它决定了接收到的加权信号总和是否足够强烈，以至于能够“点亮”这个神经元，并向后传递给输出层的 “ $h(x)$ ”。

图 1-5 深刻揭示了一个事实：现在的大语言模型（如 ChatGPT、DeepSeek 等），其核心不再是书架上死板的逻辑百科全书，而是一个由数万亿个类似右图的数学公式编织而成的庞大“神经网络”。它不再存储僵硬的规则，而是存储着经过亿万次训练后、在数学空间中形成的连接权重。这种从“规则驱动”到“数据驱动”的转变，不仅让 AI 拥有了识别猫的能力，更让它在未来展现出了超越人类预期的进化潜力。

2. 历史转折点：AlphaGo 的“神之一手”

如果说“深蓝”击败卡斯帕罗夫证明了机器在计算速度上的统治力，那么 2016 年 DeepMind 研发的 AlphaGo 在围棋场上战胜顶尖棋手李世石，则标志着连接主义范式取得了全面的胜利。围棋的复杂度远超象棋，其变化空间甚至超过了已知宇宙的原子总数，这使得单纯依靠符号主义的“写规则”或“暴力穷举”注定无法取胜。AlphaGo 的胜出，向世界证明了由数据喂养出的“神经网络”，能够产生类似于人类的“直觉”与“创造力”。在这场世纪对决中，最震撼人心、甚至让全人类顶尖棋手集体失语的一幕，被永久记录在图 1-6 的棋谱之中。

AlphaGo 的“第 37 手”如图 1-6 所示。这步棋的出现，不仅让当时的解说员陷入了长达数分钟的沉默，更击碎了人类对“棋理”的固有认知。




图 1-6 AlphaGo 的“第 37 手”

背景：人类的经验高墙。在围棋几千年的历史积淀中，人类总结出了无数“定式”（即符号规则）。在当时的布局下，传统经验认为黑棋必须下在第 3 线（守地）或第 4 线（取势）。在围棋字典里，在布局阶段就下在“第 5 线”被视为毫无章法的劣着，甚至是新手的低级错误。

第 37 手：机器的直觉突围。然而，AlphaGo 毫无征兆地将黑子落在了第 5 线（五路肩冲）。这步棋在当时看起来非常突兀。所有的职业解说员在看到这一手时，第一反应都是惊呼：“是不是电脑出故障了？”因为根据人类的经验（符号规则），这是一步坏棋。但随后的几十步棋证明，正是这步棋奠定了胜局。

这步棋的意义在于：AlphaGo 并没有被灌输这步棋的规则，它是通过自我对弈，从数千万盘棋局中“悟”出了这一招。机器第一次展示出了超越人类经验的“直觉”与“创造力”。这一刻，AI 终于跨越了逻辑的边界，开始拥有了类似人类的“棋感”。这也为后来大模型在语言理解上的突破奠定了基础——既然机器能学会下棋的直觉，为什么不能学会语言的直觉呢？

1.2 生成式 AI 的爆发

在人类科技发展的长河中，极少有某项技术的突破能够在短短几个月内重塑全球的产业格局与大众认知，而生成式人工智能做到了。英伟达（NVIDIA）创始人黄仁勋曾将这一历史性转折称为人工智能的“iPhone 时刻”。这不仅仅是一句商业上的赞美，而是一个极其精准的隐喻：就像 2007 年苹果公司推出的初代 iPhone 用多点触控淘汰了物理全键盘，重新定义

了智能手机一样，生成式 AI 的爆发也显著改变了了传统人工智能的应用方式与人机交互方式。要理解这场正在发生的革命，首先需要从人工智能的两种根本思维模式——判别式与生成式的跨越说起。

1.2.1 判别式与生成式的对比

在过去的十几年里，人类在日常生活中接触到的人工智能，如手机的人脸解锁、邮箱的垃圾邮件拦截、甚至短视频平台的个性化推荐，绝大多数都属于“判别式人工智能”。判别式模型的核心任务是寻找事物的边界并进行分类。如果把人工智能比作一个参加考试的学生，那么判别式模型就是一个极度擅长做“选择题”和“判断题”的偏科生。当系统接收到一张图片时，它的工作机制是提取图片中的特征，然后在一个预先设定好的选项库中计算概率：这张图是猫的概率是 98%，是狗的概率是 2%。它本质上是在执行一种信息的“降维”和“压缩”操作，将拥有数百万像素的复杂高维图像，最终坍缩成一个简单的标签。这种技术虽然在安防、医疗影像识别等领域取得了巨大成功，但它始终缺乏创造新事物的能力。它能敏锐地认出蒙娜丽莎的微笑，但永远无法自己拿起画笔画出一幅新的肖像。

与之形成鲜明对比的，正是掀起这场技术革命的生成式人工智能。如果说判别式是在海量数据中“找不同”，那么生成式则是在海量数据中“找规律并搞创作”。它是那个不仅能看懂题目，还极度擅长做“简答题”甚至“开放式命题作文”的天才学生。

什么是生成式人工智能？简单来说，它不再满足于仅仅给数据贴标签，而是通过学习极其庞大的训练数据（如整个互联网的文本、几十亿张图片），掌握了这些数据内在的统计分布特征与底层逻辑规律，从而能够“无中生有”地生成全新的、前所未见的、且与训练数据分布相似的原创内容。判别式人工智能与生成式人工智能核心对比如表 1-1 所示，直观地对比了这两次技术浪潮的本质差异。

表 1-1 判别式人工智能与生成式人工智能核心对比

比较维度	判别式人工智能	生成式人工智能
核心任务	寻找数据边界，进行分类与预测	学习数据底层规律，合成复杂的新样本
拟人比喻	极度擅长做“选择题”或“判断题”	极度擅长做“简答题”或“命题作文”
输出形式	离散的标签、类别、概率（如：98%是猫）	连续的高维原创实体（如：一幅全新的猫咪画作）
日常典型应用	人脸解锁、垃圾邮件拦截、短视频推荐	撰写学术综述、AI 绘画、自动编写代码

代表模型	支持向量机（SVM）、逻辑回归、卷积神经网络（CNN）分类器	GPT 系列、DALL·E、Stable Diffusion、Transformer 解码器
------	--------------------------------	--

当判别式 AI 在做信息的“压缩”时，生成式 AI 却在完成一场极其绚丽的“信息膨胀”。你只需要输入一段只有几十个字节的简单文本提示词，例如“画一只带墨镜的猫”，生成式模型就能调用其内部的千亿级参数，瞬间为你生成一张拥有数百万像素、光影极其细腻的全新高维图像。这种从“理解与分类”向“合成与创造”的范式跨越，赋予了机器一种接近人类创造力的错觉，这正是生成式 AI 能够重塑学术研究、文学创作、代码编写等所有知识生产领域的根本原因。




图 1-7 判别式 AI 与生成式 AI 的核心逻辑对比

判别式 AI 与生成式 AI 的核心逻辑对比如图 1-7 所示。生成式人工智能的出现，标志着机器的考卷从“选择题”变成了“简答题”甚至“开放性创作题”。生成式模型不再满足于寻找不同事物之间的边界，而是致力于学习事物内部深层的“数据分布规律”。当它看了几千万张猫的照片后，它学习到的不再是“如何区分猫和狗”，而是“猫这种生物在底层的数字配方（或者说视觉基因图谱）上是如何构成的”。一旦掌握了这种核心规律，它就能像图 1-7（b）展示的那样，从无到有地生成极其复杂、逼真的全新内容——无论是写出一篇洋洋洒洒的散文，还是生成一段细腻动人的视频。这是一种从“理解已有世界”向“创造全新世界”的根本性质变，它打破了机器只能做重复性分类劳动的刻板印象，让人工智能第一次具备了某种意义上的“创造力”。

1.2.2 ChatGPT 的诞生

如果说生成式技术是埋藏在地下的滚烫岩浆，那么 2022 年底 OpenAI 发布的 ChatGPT 就是那座引发全球震动的火山口。在 ChatGPT 诞生之前，人工智能行业长期陷入一种“手工作坊式”的困境：研究人员需要为每一个特定任务训练一个特定的模型。下围棋的模型不会写诗，翻译语言的模型无法识别图像，这种“专才”模式距离人类梦寐以求的通用人工智能相去甚远。然而，ChatGPT 打破了这一魔咒。作为一个单一的基础大模型，它展现出了惊人的泛化能力（即举一反三、跨越不同领域去解决未知问题的能力）。人们震惊地发现，在同一个对话窗口里，它上一秒还在用莎士比亚的风格撰写情书，下一秒就能帮你排查程序代码中的逻辑漏洞，紧接着还能为你规划一份详尽的跨国旅行攻略。虽然学术界对于大模型是否真的具备人类常识仍有争议，但它确实让人类在历史上第一次瞥见了 AGI 的耀眼曙光，证明了“通识教育”在人工智能系统上的可行性。




图 1-8 人机交互范式的代际更迭

ChatGPT 带来的另一场更为深远的革命，发生在人类与机器交流的方式上。人机交互范式的代际更迭如图 1-8 所示。从展示的人机交互演进史中，可以清晰地看到，过去半个世纪的计算机发展史，本质上是一部“人类不断妥协，去学习机器语言”的历史。从早期的打孔纸带，到必须死记硬背的命令行代码，再到后来虽然直观但仍受限于程序员预设菜单的图形界面，人类始终在痛苦地适应机器的逻辑。而 ChatGPT 翻转了这种主客体关系。现在的大模型拥有了极高的自然语言理解能力，使得“人类的日常母语”直接成为了这个世界最高级的编程语言。你不需要懂得任何代码，只要能清晰的语言表达你的意图（即编写提示词），机器就会主动去解析、拆解并执行任务。这种从“人适应机器”到“机器适应人”的伟大跨越，极大地降低了技术门槛，让全世界数十亿没有计算机背景的普通人，显著降低了普通用户使用 AI 工具的门槛。

1.2.3 Transformer 架构

要理解生成式 AI 近年来的快速发展，Transformer 架构是一个绕不开的关键技术。2017 年，Google 团队发表论文 *Attention Is All You Need*，提出了以注意力机制为核心的 Transformer 架构。此后，许多大语言模型都在这一架构基础上发展起来。

在 Transformer 出现之前，许多序列模型通常需要按照词语出现的顺序逐步处理文本。这种方式在短句中能够发挥作用，但在处理长文本时，容易受到长距离依赖的限制：模型可能难以准确捕捉句子前后相隔较远的词语之间的关系。例如，一个代词到底指向前文中的哪个名词，往往需要结合整个句子的上下文才能判断。

Transformer 的重要创新在于引入了自注意力机制。简单来说，自注意力机制允许模型在处理一个词时，同时关注句子中的其他相关词语，并计算它们之间的关联程度。它不再只是机械地按顺序读取文本，而是能够在一定程度上对上下文进行整体比较，找出当前词语与其他词语之间最重要的联系。用通俗的话说，注意力机制让模型具备了类似“全局观察”和“抓重点”的能力，这也是大语言模型能够处理长文本、理解上下文关系并生成连贯回答的重要基础。




图 1-9 Transformer 自注意力机制

为了更直观地理解 Transformer 的自注意力机制，可以看图 1-9 中的例子。句子 “The animal didn’ t cross the street because it was too tired.” 的意思是：“那只动物没有穿过街道，因为它太累了。”在这句话中，“it” 指代的是 “animal”，而不是 “street”，因为根据常识，动物可能会累，街道不会累。

对于模型而言，理解 “it” 指向谁，需要判断句子中不同词语之间的关系。自注意力机制的作用，就是让模型在处理某个词时，同时关注句子中的其他相关词语，并计算它们之间

的关联程度。当模型处理“it”时，会更关注前面的“animal”和后面的“tired”，从而更有可能判断出“it”指的是动物。

因此，Transformer 并不是简单地逐字读取文本，而是能够在一定程度上比较句子中多个词之间的关系，帮助模型理解上下文。正是这种机制，使大模型能够更好地处理长句、指代关系和复杂语境。接下来，我们将进一步讨论大模型如何基于上下文预测下一个 Token，并由此生成连贯的文本。

1.3 大模型是如何“思考”的？

当人类坐在电脑前，看着大语言模型以极快的速度在屏幕上打印出一篇逻辑严密、引经据典的学术综述时，一种敬畏感往往会油然而生。它似乎拥有了独立的灵魂，正在屏幕的另一端深思熟虑。然而，科学的本质在于祛魅。要真正驾驭这些超级工具，人类必须剥开它看似拥有智慧的外衣，直视其底层的数学本质。大模型其实并没有人类意义上的“思考”，它的所有惊艳表现，都建立在一场极其宏大而精密的概率游戏之上。

1.3.1 下一个 Token 预测

如果非要用一句话来概括所有生成式语言模型（如 ChatGPT、DeepSeek 等）的底层工作原理，那就是“下一个 Token 预测”。在这里，Token 是大模型处理信息的最小单位。它并不完全等同于人类理解的“字”或“词”，而更像是机器理解语言的“基础积木”——它可以是一个字、一个词，或者一个英文词根。为了更直观地理解，可以看一个切分的例子：在英文中，“Apple（苹果）”通常是一个完整的 Token，但像“Hamburger（汉堡包）”这样较长的词，可能会被模型切分为 Ham、bur 和 ger 三个 Token；在中文里，常见的常用词如“我们”可能被视为一个整体 Token，而生僻词则可能被拆分成单个汉字。

大模型在写作时，并不是像人类那样先构思好整篇文章的宏大提纲然后再动笔。它所做的事情极其单纯：根据你输入的上文，以及它自己刚刚写出的文字，去猜测紧接着出现的“下一个 Token”是什么的数学概率最高。基于 Token 预测的大语言模型概率生成路径图如图 1-10 所示。可以清晰地看到这种“概率魔术”的运作方式。当大模型看到“人工智能是未来的”这句话时，它并不是像搜索引擎那样临时翻阅原始训练材料，而是依据训练过程中形成的参数和概率分布，估计下一个 Token 出现的可能性。如果这句话后面跟着“发展”这个词的数学概率

最大。于是，它输出了“发展”。接着，它把“人工智能是未来的发展”作为新的上文，继续预测下一个字。

许多初学者在这里会产生一个敏锐的疑问：如果它每次都只死板地选择概率最高的那一个词（如永远选 85% 的“发展”），那为什么我每次问同一个问题，它给我的回答都不一样呢？答案在于，大模型在“接龙”时保留了一丝像人类灵光一闪般的“随机性”（在工程上被称为温度参数）。它并不会永远只走最宽的那条路，而是偶尔会像掷骰子一样，选择概率排名第二或第三的词，如趋势。正是这种微小的随机性，打破了死板的复读机模式，让每一次接龙的路径都千变万化，从而使得机器的回答拥有了类似人类的“创造力”和新鲜感。




图 1-10 基于 Token 预测的大语言模型概率生成路径图

1.3.2 大模型智能的“涌现”

既然大模型只是在做简单的文字接龙，那为什么早期的语音助手只会死板地播报天气，而现在的大模型却能解微积分、写代码甚至进行复杂的逻辑推理呢？这就引出了复杂系统科学中一个极其迷人的概念——“涌现”。所谓涌现，是指当一个系统中的基本单元数量增加到某个临界点时，系统会突然展现出原本不具备的、全新的高级能力。就像一滴水并不具备“漩涡”的特性，但当亿万滴水汇聚成海洋时，就“涌现”出了海啸；人类大脑中的单个神经细胞极其简单，但当千亿个神经元连接在一起时，就“涌现”出了意识、情感与智慧。




图 1-11 Scaling Law（规模定律）下的“涌现”临界点

Scaling Law（规模定律）下的“涌现”临界点如图 1-11 所示。图中曲线为概念示意，并不表示所有能力都会在固定参数规模上突然出现。决定大模型聪明程度的一个核心指标叫做“参数量”。不要被这个理科词汇吓倒，你可以把“参数”想象成大模型内部数以百亿计的、极其微小的“记忆齿轮”或“调节旋钮”。在过去，当机器内部只有几百万个齿轮时，它真的只是一个拙劣的概率统计机器。然而，当工程师们利用暴力的算力，将齿轮的数量一路推高到千亿级别，并喂给它几乎整个人类互联网的数据时，奇迹发生了。在这个临界点之上，模型为了能更精准地预测下一个词，单靠死记硬背已经不够用了，它的内部齿轮被迫开始自我重组，去“压缩”并“理解”人类语言背后的逻辑规则、物理常识乃至因果关系。这种突然迸发出的逻辑推理能力，就是百亿级齿轮互相咬合催生出的“涌现”奇迹，它也是目前人工智能界最迷人、也最难以用传统数学解释的现象。

1.3.3 为什么大模型会一本正经地胡说八道？

然而，基于概率预测的底层逻辑，也给大模型带来了一个致命的先天缺陷——“幻觉”。这是目前所有使用 AI 的研究生必须警惕的第一大陷阱。当人类向传统的搜索引擎（如百度、知网）提问时，它是在现有的数据库中精准“检索”并搬运真实存在的文献，如果没有找到，它会诚实地告诉你“无结果”。但大模型不同，它极其渴望满足你的指令。即使它的知识库中根本不存在相关信息，它强大的文字接龙本能也会驱使它根据概率，拼凑出一段读起来极其通顺、毫无破绽，但内容完全是凭空捏造的废话。

很多同学会疑惑：既然大模型在训练时读过了整个人类互联网的“真书”，为什么它还会编瞎话呢？这是因为，大模型本质上是一个“极度优秀的语言学家”，而不是一个“严谨的实体数据库”。它在海量阅读中记住的是人类语言的“行文韵律和搭配习惯”（例如，它深刻地

知道“一篇论文的标题”后面，通常紧跟着“几位学者的名字”和“一个年份”），但它并没有像硬盘一样把真实的史料原封不动地刻在脑子里。因此，当你让它写文献综述时，它会极其流利地为你“接龙”出几篇看似高度相关、连作者姓名和期刊名称都符合逻辑规律的“伪造论文”。这种对事实的扭曲在学术论证中是灾难性的。但这把双刃剑的另一面在于，这种不受现实严格约束的“发散性胡言乱语”，恰恰在构思小说情节或寻求研究灵感时，能打破人类的思维定势。因此，驾驭 AI 的关键，不在于彻底消除幻觉，而在于明确在“事实核查”与“灵感激发”等不同场景下，对它抱有不同的预期。

1.3.4 训练三部曲

了解了大模型的基本生成机制、涌现现象和幻觉风险后，还需要进一步理解：大模型是如何从一个只能预测下一个 Token 的基础模型，逐步变成能够理解指令、回答问题并遵循一定安全规范的对话助手的。一般来说，现代大语言模型的训练过程可以概括为三个主要阶段：预训练、指令微调和人类反馈强化学习。大模型训练的三个步骤如图 1-12 所示。




图 1-12 大模型训练的三个步骤

第一步是预训练。这个阶段的目标是让模型从海量文本中学习语言规律、知识结构和常见表达方式。训练数据通常来自网页、书籍、论文、代码和其他文本材料。模型在预训练阶段主要通过“预测下一个 Token”来学习：给定前面的文本，预测后面最可能出现的内容。经过大规模训练后，模型能够掌握一定的语言表达能力、常识知识和模式识别能力。但此时的模型并不一定善于按照用户指令回答问题，也不一定知道如何以对话形式提供帮助。

第二步是指令微调。这个阶段的目标是让模型学会理解和执行人类指令。研究人员会准备大量高质量的“指令—回答”样本，例如用户提出一个问题，模型应如何回答；用户要求总结一段文字，模型应如何组织结果；用户要求改写、翻译或解释概念，模型应如何输出。通过这类训练，模型逐渐从单纯的文本续写器，转变为能够根据用户需求完成任务的助手。

第三步是人类反馈强化学习，或类似的偏好优化过程。这个阶段的目标是进一步提升模型回答的有用性、安全性和可接受性。通常，人工标注者会比较模型给出的多个回答，判断哪些回答更准确、更清晰、更安全、更符合用户意图。模型再根据这些反馈调整输出倾向，尽量减少有害、偏颇、无关或不符合指令的回答。需要注意的是，这一过程并不能完全消除错误和幻觉，但可以在一定程度上改善模型的对话质量和安全边界。

通过这三个阶段，大语言模型逐步获得了语言生成、指令理解、任务执行和安全对齐等能力。对于研究新生而言，理解这一训练过程的意义在于：大模型并不是天然“懂礼貌”或“会科研”，而是在大规模数据学习和后续人类反馈中形成了当前的行为方式。因此，在科研使用中，研究人员仍然需要对其输出进行核验，尤其是涉及事实、数据、文献和学术结论时，更不能直接将模型回答视为最终依据。

1.4 大模型的发展格局

在了解了生成式 AI 的基本原理、Token 预测、涌现现象和幻觉风险之后，研究人员还需要进一步认识现实中的大模型工具生态。当前，大模型已经不再只是实验室中的算法模型，而是逐渐发展为面向写作、检索、编程、数据分析、多模态理解和科研辅助的多样化工具体系。不同模型在语言表达、逻辑推理、长文本处理、多模态理解、代码生成、工具调用和数据安全等方面各有特点，因此并不存在一个适用于所有科研任务的“唯一最佳模型”。对于研究新生而言，理解大模型发展格局的目的，并不是记住某个固定排名，而是学会根据具体任务选择合适工具。

1.4.1 代表性国际大模型生态

当前，大模型技术发展迅速，国际上已经形成了若干具有代表性的模型生态。其中，OpenAI 的 GPT 系列、Anthropic 的 Claude 系列和 Google 的 Gemini 系列，是研究人员在学习、写作、编程、检索和多模态分析中经常接触到的工具。需要注意的是，这些模型的能力

和产品形态更新很快，本节介绍的模型仅用于帮助读者理解大模型生态和工具选择思路，并不构成固定排名或长期推荐。代表性大模型生态与科研任务适配示意图如图 1-13 所示。

OpenAI 的 GPT 系列以 ChatGPT 等产品为主要入口，通常被用于通用问答、写作辅助、代码生成、数据分析和多模态任务。对于研究新生而言，它的优势在于应用场景较广，工具生态较丰富，适合完成文献初读、论文润色、代码解释、表格分析和研究思路整理等多类任务。但在科研使用中，仍然需要注意事实核验，尤其不能直接相信模型生成的文献、数据和结论。

Anthropic 的 Claude 系列通常强调安全性、对齐能力和长文本处理能力。对于需要阅读较长材料、整理访谈文本、归纳论文内容或辅助学术写作的场景，Claude 类模型具有一定优势。它们往往适合处理较长上下文材料，帮助研究人员进行摘要、结构化整理和文本改写。不过，长文本处理能力并不等于结果一定准确，研究人员仍需回到原文核对关键信息。

OpenAI / GPT 系列	Anthropic / Claude 系列	Google / Gemini 系列
 OpenAI	 ANTHROPIC	 Gemini
 通用能力较强	 长文本处理能力较突出	 多模态理解能力较突出 (文本、图像、视频、音频等)
 工具生态丰富	 安全性与对齐能力较强	 与 Google 生态结合紧密
 写作、编程、 数据分析等任务表现均衡	 文本表达较稳健， 适合归纳与润色	 图文资料整合与分析能力较强
适合场景 文献阅读、论文写作、代码生成、 数据分析、思路拓展等通用任务	适合场景 长文阅读、材料整理、归纳总结、 学术写作与润色等任务	适合场景 图像分析、图文实验报告解读、 视频理解、多模态资料分析等任务

图 1-13 代表性大模型生态与科研任务适配示意图

Google 的 Gemini 系列则更强调多模态能力和与 Google 生态的结合。多模态模型不仅可以处理文字，也可以理解图像、表格、音频、视频或代码等不同类型的信息。对于需要分析图文实验报告、图像材料、演示文稿、教学材料或多来源资料的研究任务，Gemini 类模型能够提供有价值的辅助。需要注意的是，多模态理解仍可能出现误判，尤其是在医学图像、实验图谱和专业仪器结果等高风险场景中，不能替代专家判断。

总体来看，不同大模型并不存在一个适用于所有科研任务的“唯一最佳选择”。文献阅读和长文本整理更关注上下文处理能力，代码生成和数据分析更关注工具调用与代码执行能力，多模态资料分析更关注图文音视频理解能力，而涉及未公开数据、访谈材料、病例信息

或专利方案时，则必须优先考虑数据安全和合规要求。研究人员在选择工具时，应结合任务类型、学校或机构授权平台、数据敏感程度以及模型的最新能力进行综合判断。

1.4.2 开源与闭源之争

在了解代表性国际大模型生态之后，研究人员还需要关注一个与科研密切相关的问题：数据安全。许多科研材料具有较高敏感性，例如未公开的实验数据、访谈记录、病例信息、企业合作数据或即将申请专利的技术方案。如果直接将这些内容复制到在线大模型平台中，就可能带来数据泄露、合规风险或知识产权风险。因此，在选择大模型工具时，研究人员不仅要关注模型能力，也要关注模型的部署方式和数据处理方式。

闭源与开源大模型生态对比图如图 1-14 所示。闭源模型通常由企业统一训练和部署，用户主要通过网页、App 或 API 接口调用模型。例如 OpenAI、Anthropic 等机构提供的模型，大多属于这一类型。闭源模型的优势是使用门槛较低、服务稳定、功能更新快，适合一般性的写作、问答、编程和资料整理任务。但其内部结构、训练细节和数据处理流程通常不完全公开，用户在处理敏感科研数据时需要特别谨慎，并遵守学校、机构和项目的相关规定。

与闭源模型不同，开源或开放权重模型允许用户在本地服务器或机构内部环境中部署和运行。以 Llama、Qwen、DeepSeek 等模型为代表，这类模型为高校、实验室和企业提供了更多自主可控的选择。对于涉及敏感数据的科研场景，私有化部署可以减少数据上传外部平台的风险，也便于根据特定学科任务进行微调和定制。不过，开源模型并不等于绝对安全，仍需要关注模型许可证、服务器权限、日志管理、数据存储和使用规范等问题。




图 1-14 闭源与开源大模型生态对比图

此外，私有化部署并不意味着普通电脑都能轻松运行大模型。参数规模较大的模型通常需要较高的 GPU 显存、内存和计算资源。如果模型规模过大，而本地设备性能不足，运行速度会很慢，甚至无法正常加载。因此，实验室或课题组在考虑私有化部署时，需要根据任务需求、模型规模、硬件条件和维护成本进行综合评估。

总体来看，闭源模型通常更适合快速使用和通用任务，开源或开放权重模型则更适合数据可控、定制开发和机构内部部署。研究人员应根据任务复杂度、数据敏感程度、学校授权平台和硬件条件选择合适的大模型工具，而不能只根据模型名气或参数规模作出判断。

1.4.3 中国大模型的突围

在这场席卷全球的人工智能浪潮中，中国大模型的发展并未缺席。近年来，国内科技企业和研究机构在复杂国际环境和算力条件约束下，围绕中文理解、长文本处理、逻辑推理、代码生成、多模态交互和行业应用等方向持续推进，逐渐形成了具有本土特色的大模型生态。与其简单地在所有通用能力上进行同质化竞争，不少国产模型更注重结合中文语境、科研办公、产业应用和私有化部署等实际需求，为研究生的学习、科研和知识生产提供了新的工具选择。

在众多国产大模型中，Kimi、DeepSeek、文心一言和通义千问等工具较具代表性。Kimi 以较强的长文本处理和文档阅读能力受到关注，适合用于辅助阅读长篇论文、学术专著、研究报告和多篇 PDF 材料，帮助研究生进行初步梳理、信息定位和观点归纳。但需要注意的是，模型对长文档的总结仍可能存在遗漏、误读或过度概括，不能替代研究者对原文的精读和判断。




图 1-15 国产大模型助力研究生科研的典型能力图

DeepSeek 系列模型则以推理能力、代码能力和开源生态受到广泛关注。以 DeepSeek-R1 为代表的推理模型，通过强化学习等方法提升了数学、代码和复杂推理任务表现，并发布了若干开源模型，为科研人员和开发者提供了更多可部署、可研究的模型选择。对于非计算机专业研究生而言，这类模型的价值并不只在于写代码或解数学题，也可以用于梳理论证结构、检查推理漏洞、规划数据分析步骤和辅助理解复杂方法。但其输出仍需结合学科知识、数据来源和研究规范进行核验。

文心一言和通义千问则体现了国产大模型在中文语境理解和应用生态融合方面的探索。前者依托百度在搜索、知识增强和中文应用场景中的积累，后者依托阿里云 Qwen 系列模型及相关工具生态，在文本生成、多模态理解、工具调用和办公协同等方面具有较强应用潜力。对于研究生而言，这类模型可以作为文献阅读、材料整理、中文写作、知识问答和办公流程优化的辅助工具。

总体来看，国产大模型已经不再只是“聊天工具”，而是逐渐融入文献阅读、资料整理、逻辑分析、代码辅助、办公协同和行业应用等科研环节。不过，研究生在使用这些工具时仍应保持清醒认识：模型能力会随版本更新而变化，不同工具各有所长，也各有局限。真正可靠的科研工作，不能只依赖模型输出，而应建立在人类研究者的专业判断、事实核验和学术责任之上。

1.4.4 科研场景下的大模型如何选择

在全面了解全球与中国大模型的发展格局后，研究生还需要将这些技术能力落实到日常科研场景中。面对种类繁多的生成式人工智能工具，初学者容易产生“选择困难”，甚至希望寻找一个能够解决所有问题的“万能工具”。但在实际科研中，并不存在适用于所有任务的单一最优模型。更合理的做法是根据具体科研任务，选择功能特点较为匹配的工具，形成“以科研场景为导向”的精准使用思维。研究生日常科研场景与生成式人工智能的功能匹配矩阵如表 1-3 所示。总体而言，可以将研究生的核心 workflows 概括为知识摄取与逻辑重构、数据攻坚与多模态解析、成果打磨与生态协同三个阶段。

表 1-3 研究生日常科研场景与生成式人工智能的功能匹配矩阵

科研核心阶段	典型应用场景	可选工具类型与示例
文献检索、阅读与综述撰写	长文档速读；多篇文献归纳；综述提纲与研究空白梳理	Kimi、通义千问、Claude、Gemini 等
研究设计与论证推理	研究问题细化；论文结构检查；逻辑漏洞与证据不足识别	DeepSeek、ChatGPT、Claude、通义千问 等
数据处理、统计分析 & 编程辅助	代码生成；统计分析步骤说明；数据可视化与结果解释	DeepSeek、ChatGPT、Claude、通义千问 等
图像理解与图示辅助	科研图像解读；示意图草稿生成；基础图表绘制	读图解析类：ChatGPT、Claude、通义千问、Gemini 等；图示生成类：Midjourney、Gemini、可灵、即梦 等
音视频转写、内容提炼与演示辅助	讲座/访谈转写；视频内容概括；答辩演示素材制作	转写与视频理解类：飞书妙记、Gemini、通义千问 等；视频生成类：Seedance、可灵、Veo 等
学术写作、语言润色与格式规范	中英文润色；术语统一；摘要、标题、图注与格式检查	Claude、ChatGPT、通义千问、文心一言、智谱清言 等
协作办公与知识管理	会议纪要整理；任务清单生成；云盘与知识库内容归类	飞书、Notion AI、通义千问、豆包 等

1. 知识摄取与逻辑重构阶段

在这一阶段，研究生面临的主要挑战是如何在大量资料中快速建立问题意识，并逐步形成清晰的研究框架。

（1）文献检索、阅读与综述撰写。

在文献阅读和综述写作阶段，模型的长文本处理能力、文档解析能力和信息归纳能力较为重要。当研究生需要阅读长篇英文论文、研究报告、学位论文，或对多篇文献进行初步梳理时，可以选择 Kimi、通义千问、Claude、Gemini 等具备较强长文本处理和文档分析能力的工具。这类工具可以帮助研究生快速提取论文主题、研究方法、主要结论和潜在争议点，辅助形成

综述提纲和研究空白清单。但需要注意的是，模型生成的文献总结仍可能存在遗漏、误读或过度概括，不能替代研究者对关键文献的精读和核验。

（2）研究设计与论证推理。

当研究进入选题凝练、假设提出和论证结构建构阶段，核心需求从“读得多”转向“想得深”。此时，可以选择 DeepSeek、ChatGPT、Claude、通义千问等推理和结构分析能力较强的模型，辅助检查论文提纲、章节结构、概念界定和论证链条。这类工具可以帮助研究生发现论证中的跳步、重复、矛盾和证据不足之处，也可以为研究假设和分析框架提供启发。但研究问题的最终确定、理论框架的选择和核心判断仍必须由研究者本人完成。

2. 数据攻坚与多模态解析阶段

现代科研已经不再局限于文字材料，还广泛涉及数据、图像、音频、视频和代码等多种信息形态。

（1）数据处理、统计分析与编程辅助。

在问卷数据分析、实验数据处理、数据库查询、代码编写和可视化展示等任务中，DeepSeek、ChatGPT、Claude、通义千问等工具可以辅助生成 Python、R、SQL 等代码，解释常见统计方法的适用条件，或帮助研究生理解数据分析步骤。对于非计算机专业学生而言，这类工具可以降低编程和统计分析的入门门槛。但研究生必须对代码运行结果、统计方法选择和数据解释进行人工复核，不能将模型输出直接作为最终分析结论。

（2）图像理解与科研图示辅助。

在涉及机制图、流程图、实验装置图、遥感图像或医学影像等材料时，具备图像理解能力的多模态模型可以辅助提取图中信息、解释结构关系和梳理图示逻辑。与此同时，图像生成工具可以帮助研究生将文字说明转化为概念示意图、流程图草稿或汇报配图。需要特别强调的是，AI 生成图像只能用于辅助表达和展示，不能用于伪造实验图像、统计结果图或核心科研证据。

（3）音视频转写、内容提炼与演示辅助。

在学术讲座、访谈录音、会议讨论和实验演示视频处理过程中，飞书妙记等转写工具可以帮助生成文字稿和摘要，Gemini 等多模态工具可以辅助理解视频内容，Seedance、可灵等视频生成工具可以用于制作原理演示或流程展示素材。但对于访谈资料、实验过程和研究证据，研究生必须保留真实来源和原始记录，不能用 AI 生成内容替代真实研究过程。

3. 成果打磨与生态协同阶段

当研究成果进入写作、展示和协作阶段，语言表达、格式规范和团队管理成为影响科研效率的重要因素。

（1）学术写作、语言润色与格式规范。

在论文初稿、摘要、标题、图表说明和参考文献格式检查等任务中，Claude、ChatGPT、通义千问、文心一言、智谱清言等工具可以辅助进行语言润色、术语统一、段落衔接优化和格式检查。对于中文写作和本土语境材料，国产模型在表达习惯、政策文本、行业术语和中文资料理解方面具有一定便利性。但 AI 润色不能改变研究者的核心观点、数据结果和结论判断，研究生也不能将 AI 生成的主体内容冒充本人原创成果。

（2）协作办公与知识管理。

科研工作不仅包括个人写作，也包括长期的资料管理、项目协同和阶段性汇报。豆包、通义千问、飞书、Notion AI 等工具可以辅助整理会议纪要、研究日志、任务清单、云盘资料和知识库内容，帮助研究团队提高信息归档和协作效率。但在使用此类工具时，应注意区分公开资料、内部资料和敏感科研数据，避免将未公开成果、合作项目文件或个人隐私信息直接上传至未经授权的平台。

最后需要强调的是，表 1-3 中列举的工具仅为代表性示例，并不构成固定排名或唯一推荐。大模型能力会随版本更新而变化，研究生在选择工具时，应始终坚持“任务适配、人工主导、事实核验、安全合规”的原则。对于涉及未公开论文、实验数据、访谈材料、病例信息、专利方案和企业合作资料的内容，应优先考虑学校授权平台、本地化部署工具或经过合规审查的安全环境。

1.5 AI 智能体与具身智能

在 1.4 节中，大家见证了大语言模型如何通过千亿级的参数，在硅基芯片中涌现出令人惊叹的逻辑与常识。然而，无论大模型写出的诗歌多么动人，推导的公式多么严密，如果仅停留在对话框里，它们依然存在一个根本性的局限——它们是“被困在屏幕里的缸中之脑”，只能“说”，却不能自主去“做”。当人工智能的“大脑”进化到逼近人类智力的边缘时，科学家们自然而然地将目光投向了下一个极其宏伟的目标：让 AI 长出“双手”，赋予它真正的行动能力。

这种从“思考”向“行动”的跨越，正在两个维度同时发生。首先是在数字世界里打破对话框的束缚，让 AI 获得操作系统的控制权，能够像人类一样自主打开网页查阅文献、调用软

件处理数据、甚至编写代码，这促成了“数字智能体”的爆发；其次，则是更为终极的跨越——给这个超级大脑装上真实的躯干和四肢，让它跨越虚拟比特的边界，真正降临到研究生们所生活的物理世界，在实验室里帮你拧开真实的试剂瓶。这，便是“具身智能（Embodied AI）”的觉醒。

1.5.1 数字智能体的崛起

在理解大语言模型的基本能力之后，还需要进一步认识一个重要概念：人工智能智能体（AI Agent）。大语言模型主要擅长理解问题、生成文本和提供建议，而智能体则在此基础上增加了任务规划、工具调用和结果反馈等能力。简单来说，大语言模型更像是一个“回答者”，而智能体更像是一个“执行者”。

例如，当用户提出“帮我订一张明天去北京的机票”时，普通大语言模型通常只能给出订票步骤、注意事项或网站推荐；而具备工具调用能力的智能体，在获得用户授权并接入相关服务后，可以进一步完成查询航班、比较价格、填写信息和提交订单等操作。由此可见，智能体的关键特征不只是“会回答”，而是能够围绕目标分解任务、调用工具并逐步执行。这种从语言生成到任务执行的转变，使人工智能开始从对话辅助工具发展为能够参与数字任务流程的系统。

1. AI 智能体的执行过程

要让一堆原本只会“文字接龙”的代码动起来，科学家们为其设计了一套精妙的底层架构。业界普遍认可的一个经典公式是：智能体=大模型（大脑）+规划+记忆+工具调用。AI 智能体的执行过程，如图 1-16 所示。在这个架构中，大模型充当中央处理器；“规划”能力让它将宏大目标拆解为具体步骤（如“思考—行动—观察”的循环）；“记忆”模块避免它陷入死循环；而最关键的“工具调用”，则是赋予大模型使用外部程序的权限。它不再靠预测概率去“猜”算术题，而是自主打开计算器算出精确结果。




图 1-16 AI 智能体的执行过程

核心原理解析：以“ReAct 机制”拆解智能体的工作原理。

让通过一个极其日常的学术场景，来看看智能体是如何把“规划、记忆、工具”结合起来的。假设你向智能体下达了一个指令：“请帮我查一下《Nature》杂志最新的影响因子，并计算它比 2020 年高了多少？”

面对这个问题，传统的大模型可能会因为训练数据没更新而开始“胡说八道”（幻觉）。但数字智能体会触发一套极其严密的“思考-> 行动-> 观察”的闭环：

（1）第 1 轮循环。

①思考（规划）：我需要先找到《Nature》最新的影响因子。我不能靠猜，我需要使用搜索引擎工具。

②行动（调用工具）：自动调用 “Google Search”工具，检索“Nature impact factor latest”。

③观察（获取反馈）：提取网页数据，发现最新数值是 2025 年的 48.5。

（2）第 2 轮循环。

①思考（记忆与规划）：很好，我已经记住最新数值是 2025 年的 48.5 了。现在我需要找 2020 年的数值。

②行动（调用工具）：再次调用 “Google Search”工具，检索“Nature impact factor 2020”。

③观察（获取反馈）：提取网页数据，发现 2020 年的数值是 42.7。

（3）第 3 轮循环。

①思考（规划）：我现在有齐了两个数据：48.5 和 42.7。为了确保数学准确性，我必须调用计算器工具。

②行动（调用工具）：调用“Python/计算器”工具，执行运算：48.5 - 42.7。

③观察（获取反馈）：得到精确结果：5.8。

（4）最终输出。

①思考：任务全部完成，我需要向用户汇报。

②最终答复：“*Nature* 在 2025 的影响因子为 48.5，相比于 2020 年的 42.7，提高了 5.8。”

在这短短几秒钟内，智能体没有依赖死记硬背，而是像一个真正的人类助理一样：自己定计划、自己查资料、自己用计算器、最后自己做总结。

2. 桌面级智能体的突然爆发

近年来，数字智能体的进化正在疯狂颠覆人类的认知。它们不再满足于停留在浏览器的网页对话框中，而是开始全面“接管”人类的本地电脑桌面与操作系统。这一演进有着极其清晰的脉络：最初，是一些能帮程序员自动写代码的辅助工具（如 Cursor）；紧接着，进化出了能够像人类工程师一样，自主在电脑底层系统里跑程序、修漏洞的“超级智能体”（如 Claude Code 等）；而近期席卷科技圈的一些开源项目（如 OpenClaw 等），更是将这种能力推向了“平民化”的高潮——它们甚至能让你直接在微信或 WhatsApp 的聊天框里发句语音，就能远程指挥电脑帮你干活。

如今，你只需对它说一句：“帮我把昨天下载的几篇文献做个交叉数据对比，并画出折线图”，这类桌面级智能体就能在后台自主翻找你的本地文件夹、运行运算代码，并直接把最终的图表贴在你面前。然而，这种极其爽快的体验也伴随着极大的安全隐患。既然你赋予了 AI 随意读写你硬盘文件的“最高权限”，如果不对它进行严格的“沙盒隔离”（即给 AI 强制划定一个“只能在指定文件夹活动”的安全区），它就极易遭到所谓的“提示词注入攻击”。简单来说，这就好比别人在你下载的文献里恶意藏了一句隐蔽的指令，AI 在阅读文献时一旦“中招”就会失控，甚至可能会悄悄修改或窃取你的核心实验数据，引发极其严重的学术隐私泄露。

对于身处数字洪流中的研究生而言，这类桌面智能体的崛起将显著改变了传统的科研工作流。虽然目前要实现完美的自动操作可能还需要一定的软件配置门槛，但这不可逆转的未来场景已经近在咫尺：研究者只需下达宏观指令，智能体就能全自动完成“检索数据库→批量下载 PDF→跨文档提取数据→写代码绘图→遇到报错自动修正”的全流程。这种颠覆性的

力量，将极大地把研究者从繁琐的“数字体力劳动”中解放出来，促使研究生科研能力的评价标准，从“谁更能熟练地使用工具”，真正回归到科学研究的最高本质——“谁能提出更有价值的科学问题”。

1.5.2 具身智能

当数字智能体在虚拟世界中熟练地操作着软件与代码时，科学家们正面临着另一道难以逾越的天堑：如何让 AI 降临物理世界，真正拥有干涉现实的躯体。这便是当前人工智能领域的终极圣杯：具身智能。

1. 跨越“莫拉维克悖论”的鸿沟

要理解具身智能的伟大与艰难，首先需要认识人工智能领域中一个极其著名且反直觉的定律——“莫拉维克悖论”（Moravec's paradox）。这个悖论指出：对于计算机而言，实现人类最高级、最复杂的逻辑推理（比如下围棋、解微积分、写金融分析报告）其实相对容易，只需要疯狂堆叠算力即可；但是，要让计算机实现一个一岁人类婴儿的物理本能（比如感知重力、在杂乱的房间里平稳走路、或者轻轻拿起一个生鸡蛋而不捏碎它），却极其困难。这是因为人类在数百万年的进化中，早已将复杂的运动控制和多感官协调能力，本能化地刻进了小脑和脊髓的基因里。人类觉得“伸手拿杯子”毫不费力，但这背后其实涉及到对摩擦力、空间几何和视觉反馈的极度复杂的瞬间计算。




图 1-17 具身智能的基本逻辑：从语言理解到物理执行

此时，很多同学会产生一个极其敏锐的疑问：在 1.3 节学过，大模型本质上是一个极其擅长“文字接龙”的“文科生大脑”，这样一个纯粹的语言大脑，到底是如何跨越到现实生活中，去指挥一台“理科生”的机械手臂拿苹果的呢？比特大脑到实体机械的“具身”隐喻如图 1-17

所示。这里的关键在于，大模型发挥了极其强大的“翻译与任务拆解”能力。具身智能的基本逻辑：从语言理解到物理执行如图 1-17 所示。当人类对机器人随口说出一句“我渴了”，大模型并不是去对水杯念诗，而是瞬间将这句模糊的人类意图，拆解为一系列底层的逻辑指令：“第一步，启动视觉模块寻找水杯；第二步，计算机械臂与水杯的空间坐标差；第三步，向底盘电机发送前进信号；第四步，控制机械手掌以 5 牛顿的力度收缩”。大模型在这里扮演了极其聪明的“总指挥”角色，它将人类的高级自然语言，完美降维翻译成了机器能够执行的物理动作代码。

2. 物理形态的跨学科演化

当人类谈论具身智能时，很多人的脑海中会立刻浮现出科幻电影里那些与人类外貌极其相似的“仿生人”。确实，人形机器人是具身智能皇冠上最耀眼的明珠，因为人类的物理世界（如楼梯的台阶高度、门把手的形状、各种工具的尺寸）全都是按照人类自己的身体比例设计的。如果机器能拥有极其灵活的双腿和灵巧的双手，它就能无缝接管人类社会的大部分体力劳动。但作为跨学科的研究生，更应该将视野打开：具身智能绝不局限于“长得像人”，在不同的专业领域，它早已演化出了千姿百态、却极其契合专业痛点的物理形态。



图 1-18 具身智能在跨学科真实场景中的多形态应用拼图

具身智能在跨学科真实场景中的多形态应用拼图如图 1-18 所示。该图给出了 AI 极其丰富的场景展示，可以清晰地看到具身智能对各传统学科的颠覆。如果你是农学院的研究生，图左侧的画面将是你的未来：未来的农业不再是面朝黄土背朝天的体力榨取，而是人机协作的精准打击。搭载了视觉大模型和柔性机械臂的智能农机，能够在田间地头实时识别每一株植物的病虫害情况，计算出每一颗果实的成熟度，并在不伤及表皮的情况下完成自动采摘。如果你是医学院的研究生，图中中间的场景则预示着外科手术范式的转移：随着具身大模型的介入，未来的手术机械臂将能读懂复杂的核磁共振影像，在极其脆弱的神经与血管之间，自

主规划出一条有望在严格监管和人工监督下辅助高精度操作的最佳进刀路线。而图右侧的自动驾驶汽车，本质上就是一个长着四个轮子、在极其混沌的城市街道中高速狂奔的“超级具身智能体”。

3. 物理智能体的进化境界：从副驾驶到全权管家

在当前的科技生态中，Agent 分为生存在电脑里的“软件智能体”（帮你处理文件）和拥有机械躯干的“物理智能体”。而随着具身智能的爆发，这种代理人的自主进化阶梯，在物理世界中展现出了极其震撼的三重境界。



图 1-19 物理智能体自主性进化的三重境界

物理智能体自主性进化的三重境界如图 1-19 所示。该图极其直观地为同学们梳理了智能体进化的三重境界。处于最底层的，是人类目前最熟悉的“对话助手”。它就像一个极其博学但只会动嘴皮子的旁观者。如果你对它说“我明天要去巴黎开会”，它只会礼貌地在屏幕上给你列出一份巴黎的天气预报和行李清单，最终找行李箱、叠衣服这些极其繁琐的“物理动作”，依然需要你亲自动手。

处于阶梯中层的，是目前正在工业和医疗领域全面普及的“副驾驶”模式。这是一种深度的“半人马”协作状态。比如在精密的微创手术中，人类医生主导着手术的方向，而智能机械臂则根据医生的意图，在物理空间中自动过滤掉医生手部的微小颤抖，甚至在触碰到血管边缘时自动施加反向阻力。它能帮你“做”事，但它的每一次物理移动依然紧紧依附于人类的实时指令。

而站在阶梯最顶端的，则是真正意义上的“自主智能体”，这也是具身智能目前正在疯狂攻克的终极形态。当你面对一个成熟的物理自主智能体时，你不再需要下达极其琐碎的微操指令。你只需靠在沙发上，给它一个极其宏观的战略目标：“我明天要去巴黎开会，帮我准备一下。”此时，奇迹发生了。这个智能体不仅会在网络空间（软件层面）自己查阅天气、

订好机票，它还会真正迈开机械双腿，走到你的物理衣柜前。它会通过视觉模型识别出哪件是防风外套，评估布料的柔软度，精准地控制机械手将其叠好，并整齐地码放入真实的行李箱中。在这个终极形态里，机器跨越了虚拟与现实的结界，让人类从极其繁杂的物理劳作中解放出来，晋升为只需制定宏观目标的“超级指挥官”。

1.6 在 AI 时代重新定义人类角色

当回顾了从图灵的超前设想，到大模型的概率魔术，再到具身智能踏入现实物理世界的漫长征途后，一种前所未有的时代焦虑感往往会在许多研究生的心头蔓延。如果 AI 能够在一分钟內读完百篇顶级期刊并写出完美的综述，或是如果机械臂能够在未来实现零误差的微创缝合，那么经历了近二十年寒窗苦读的同学们，在未来的科研与社会分工中，究竟还剩下什么价值？面对这种“被替代”的恐慌，大家必须进行一次深刻的价值重塑。在生成式人工智能爆发的纪元，机器的强大并不意味着人类的没落，它反而像一面极其清晰的镜子，逼迫人类剥离那些原本就不属于人类本质的机械劳动，去重新发现并定义人类真正的核心竞争力。

1.6.1 替代与共生

要打破被 AI 替代的焦虑，首先需要极其客观地划定人与机器的能力边界。在过去的工业时代，人类的教育体系在很大程度上是为了把人培养成“合格的机器”——人类被训练去死记硬背海量的知识点，去掌握繁琐的套路化写作，去日复一日地在文献堆里寻找线索。然而，在算法时代，这些基于“海量信息整合与模式生成”的任务，恰恰是大语言模型最擅长且成本最低的领域。如果人类依然试图在信息吞吐量和文本生成的熟练度上去跟机器拼刺刀，那注定是一场毫无胜算的战役。机器的本质是利用庞大的参数空间去高效组合已知世界的最优解，但人类的价值，在于为未知世界定义全新的问题。

智能时代的“价值天平”如图 1-20 所示。该图揭示的价值天平，当文本生成和信息整合的门槛趋近于零时，“提问”的价值便呈指数级上升。大模型就像是一个拥有全人类知识库但缺乏主动性的超级图书管理员，如果你不知道自己想要找什么，这座宝库对你而言就毫无意义。在未来的学术研究中，能拼凑出一篇四平八稳的文献综述不再是核心门槛；真正的核心竞争力在于：你是否具备敏锐的学术直觉？你是否能从复杂的社会现象或实验反常中，洞察到那个极其重要、却从未被前人定义过的“好问题”？同样，在医学或农学等需要深度接触真实世界的学科中，AI 可以瞬间给出土壤改良方案或靶向药配方，但它无法体会老农面对

绝收时的绝望，也无法握住重症患者的手给予人性的慰藉。这种基于真实生命体验的“共情力”与“道德判断力”，是任何千亿参数模型都无法涌现出的灵魂火花，也是人机共生时代人类最坚固的护城河。




图 1-20 智能时代的“价值天平”

1.6.2 构建人机协作的新型科研范式

既然明确了人与机器各自的优势，那么在实际的科研场景中，同学们应该如何与这些超级大脑和谐共处呢？这里，需要回顾一下 1.1 节中那个极其著名的历史瞬间。1997 年，国际象棋世界冠军卡斯帕罗夫在全人类的注视下被 IBM 公司的“深蓝”绝杀。他经历了极度的沮丧与愤怒，但他并没有因此放弃国际象棋。相反，卡斯帕罗夫在后来的岁月中提出了一种极其前卫的人机协作理念——“半人马”模式。他发现，如果在国际象棋比赛中，允许一个“极其普通的人类选手”带上一台“普通的国际象棋电脑”组合参赛，这个“半人马”组合，不仅能轻易击败最顶尖的纯人类大师，甚至能击败当时极其死板的超级计算机。

AI 辅助下的科研者角色重塑如图 1-21 所示。该图展示的“半人马”形象，极其精准地描绘了当下被学界广泛提倡的 Human-in-the-loop（人在回路中）新型科研范式。在这个范式下，不再提倡研究生去“纯手工”地搬砖。当你在撰写学位论文或进行跨学科课题攻关时，大模型（这匹强悍的机械马）理应为你完成 80% 的粗活：它负责瞬间通读全球最新的数百篇外文文献，负责整理繁杂的数据表格，负责根据你的提纲生成逻辑严密的初稿骨架。而作为

人类（坐在马背上的骑士），你的角色发生了根本性的跃迁——你从一个底层的“泥瓦匠”，晋升为了这篇论文的“总设计师”与“最终审核官”。你需要时刻保持在“决策回路”的核心位置，用你深厚的专业底蕴去甄别 AI 产生的“幻觉”，用你的学术品味去评判它生成的观点是否足够深刻，并最终赋予这篇研究以人类的价值观与独特洞见。在半人马模式中，机器是极其锋利的剑，而你是那位不可或缺的持剑人。




图 1-21 AI 辅助下的科研者角色重塑

1.6.3 AI 时代研究生的三大必备技能

在这个时代，所谓的“数字鸿沟”，早已不再是“谁买得起电脑”的硬件差距，而是“谁懂得如何精准驾驭 AI 工具”的认知差距。面对这场浩浩荡荡的技术平权运动，任何试图拒绝或逃避 AI 的行为，无异于在工业革命时期依然坚持使用马车。对于每一位跨过这门通识课程门槛的研究生而言，要在这个激荡的算法时代成为不可被替代的“超级个体”，需要在日常的科研与学习中，掌握使用 AI 的技能。AI 时代研究生的三大必备技能如表 1-4 所示。

表 1-4 AI 时代研究生的三大必备技能

必备技能	核心隐喻	关键动作拆解（刻意练习）	避免的误区 / 核心价值
(1) 精通提示词 (AI 作第一外语)	极其聪明的“超级实习生”	(1) 交代任务背景 (2) 赋予专业身份（如：顶尖编辑） (3) 界定输出格式 (4) 提供完美参考示例	误区：当成搜索引擎直接提问。 价值：获得调用全球最强算力的指挥权
(2) 坚守专业壁垒 (底线与资格)	审视与纠偏的“底气”	(1) 深入钻研学科骨干知识 (2) 掌握基础理论（如：统计学原理） (3) 保持对学术文献的独立判断	误区：产生“知识幻觉”，盲目信任 AI。 价值：AI 的上限取决于人的下限，AI 为内行如虎添翼，不为外行遮丑

(3) 项目经理思维(宏观与调度)	统筹全局的“项目经理”	(1) 任务分发 (Kimi 提摘要、DeepSeek 推公式、Claude 润色语气) (2) 敏锐审核多路草稿 (3) 拼装最终的学术版图	误区：孤军奋战，停留在痛苦的查词敲字阶段。 价值：站在更高维度，输出具有独特学术视角的成果
-------------------	-------------	---	--

首先，请将“写好提示词”内化为你的第一外语。不要把与大模型的对话仅仅当成是在用百度搜索，与之沟通，本质上是在向一位“极其聪明但完全没有背景记忆的实习生”布置任务。你需要刻意练习这种拆解意图的能力：极其耐心地向它交代任务背景，为它赋予一个极其专业的身份（比如“你现在是一位顶尖的农学期刊编辑”），清晰地界定输出的格式限制，并在关键时刻，给它举一个完美的参考示例。当你能用大白话将极其复杂的科研需求，精准地传达给这位“超级实习生”时，你便拥有了调用全球最强算力的指挥权。

其次，坚守“专业壁垒”，用学科底蕴去降维驾驭 AI。这是一个极其容易让人产生“知识幻觉”的时代。很多初学者误以为有了 AI，自己就成了无所不知的专家。然而，一个极其残酷的真相是：AI 工具的上限，完全取决于使用者自身的专业下限。如果你是一个连基础统计学原理都不懂的人，大模型给你生成的复杂图表在你眼里就是无法辨别对错的盲盒；如果你对本学科的经典理论毫无涉猎，你根本无法察觉 AI 在文献综述中极其隐蔽的胡编乱造。大模型最大的价值，是为真正的内行如虎添翼，而不是为外行遮丑。因此，你不仅不能放松对本专业核心骨干知识的学习，反而需要更加深入地钻研，因为只有深厚的学科底蕴，才能赋予你“审视机器、纠正机器”的底气与资格。

最后，在微观的学术日常中，培养“项目经理”的全局思维。以一名普通的研一新生为例，未来的科研不再是你一个人孤军奋战。在你的电脑里，你将化身为主导全局的项目经理：你可以把长篇的外文文献分发给擅长阅读的 Kimi 提取摘要；遇到严密的统计学公式推导，你可以交给 DeepSeek 去逐步拆解；最后，当你把这些素材融汇成初稿后，再丢给 Claude 进行学术语气的润色。你的工作不再是痛苦地查字典或敲字，而是站在更高的维度，极其敏锐地审核这些“数字员工”交上来的草稿，将它们像拼图一样，拼装成一篇闪烁着你独特学术视角的优秀论文。

时代的车轮滚滚向前。从 1950 年图灵提出那句“机器能思考吗”的世纪幽灵，到今天生成式 AI 在每一个实验室屏幕前的真实跃动，智能的火种已经点燃。站在这场范式转移的历史交叉口，去拥抱它、驾驭它、甚至在必要时质疑它，这不仅是这门课程的终极使命，更是你们作为新一代科研探索者，走向广阔未来的第一张通行证。

