

第 4 章 多模态大模型的原理与实践

科学探索的真实世界从来都不是由纯粹的文字构成的。微观视野下的细胞凋亡、宏观尺度上的星系流转，亦或是实验报告中错综复杂的散点图表，无一不强烈依赖于视觉与空间维度的精准传达。在全面剖析了纯文本大语言模型之后，本章将带领大家进入多模态大模型（Large Multimodal Models, LMM）的学习。在这里，AI 能够从一键解析复杂的实验数据波动，到利用 LMM 的图像生成能力精准渲染高质量的学术配图，再到生成直观生动的机理演示视频。

4.1 多模态大模型

在深入探讨具体的视觉图表解析与多媒体生成技术之前，建立对 LMM 底层架构与工程特性的全局认知是非常有必要的。当 AI 扩展出“视觉”与“听觉”后，其运作逻辑与应用代价发生了怎样的根本转变？本节通过剖析跨模态模型的进化原理、量化不同模态生成的算力成本阶梯，并梳理其在科研可视化质量上的发展轨迹。

4.1.1 从大语言模型到多模态大模型的进化

人类对物理世界的感知不仅依赖文字，更依赖视觉与听觉。在真实的科研工作流中，许多关键信息，例如复杂的实验流程图、数据分布的散点图，或是难以用文字精准描述的异常实验现象，往往是难以完全“文本化”的。这就迫切需要打破单一文本模态的瓶颈，让大模型真正拥有“看”和“听”的能力。

这一技术跨越的核心，在于 LMM 建立了一个统一的跨模态“语义空间”。简单来说，LMM 并非在内部简单地拼接多个独立模型，而是为底层的语言模型配备了“视觉编码器”和“音频编码器”。这些编码器如同精准的翻译官，将图像的像素分布或音频的物理波形，转化为大模型能够理解的统一特征向量（即内部语言）。大语言模型与多模态大模型的架构对比如图 4-1 所示。LLM 犹如一位只懂文字的学者，输入与输出都必须在纯文本的维度内；而进化后的 LMM 能够将不同模态来源的数据接入同一个智能中枢，实现深层的语义对齐与跨模态联合感知。

通过一个直观的学术场景来看看“描述”与“直视”的巨大差异。多模态大模型的“直视”数据分析工作流如图 4-2 所示。假设你正在分析实验室产生的一份复杂的实验折线图，图中展示了不同温度下某种催化剂的反应速率变化。如果你试图使用 LLM 来解决问题，你需要

先把图表转换成文字：你必须手动读出每一个数据点，像这样告诉模型：“X 轴是温度（20 度到 100 度），Y 轴是反应速率。在 20 度时是 5，40 度时是 12，60 度时突然跳升到了 80，但 80 度时又跌回了 10……”这种做法不仅极度繁琐且容易出错，更致命的是，通过文字描述，模型无法感知到图形视觉上那种“剧烈拐点”带来的直观冲击。




图 4-1 大语言模型与多模态大模型的架构对比

但在多模态大模型的支持下，你只需将这张折线图的照片直接上传，并附上一句简单的提示词：“这个数据的异常趋势说明了什么？”大模型能够直接“直视”图像，从而有效定位到 60 度处的异常波动，并根据视觉特征，比如该点的颜色异常或周围的离群点，迅速判断出这可能是一次“实验误操作”或“临界相变现象”。这种“一图胜千言”的能力，极大地扩展了科研人员与模型交互的边界。




图 4-2 多模态大模型的“直视”数据分析 workflow

尽管多模态感知带来了巨大的便利，但大家在利用 AI 基础设施平台构建生成式媒体模

型时，必须清醒地认识到这种进化带来的工程与资源代价。大模型处理纯语言极其高效，因为其基座最初就是为文本优化的。但在进行多模态生成时，其计算逻辑会发生显著改变。大语言模型与多模态大模型的应用特征对比如表 4-1 所总结的，纯文本生成通常具备较低的推理延迟与相对轻量化的基础算力开销，而当任务涉及到图像甚至视频的生成时，计算时长和费用成本会呈现明显的阶梯式上升。因此，在日常的协作撰稿与实验推进中，合理评估任务需求、选择最匹配的模态，是高效利用 AI 工具不可或缺的素养。

表 4-1 大语言模型与多模态大模型的应用特征对比

对比维度	大语言模型	多模态大模型
感知能力	仅限“阅读”文字	具备“阅读”、“看图”、“听音”等多维感知
输入形式	键盘打字、文档上传	文本输入、照片上传、录音提交、多图混合输入
信息传达效率	强依赖用户的文字表达能力，遇复杂视觉场景易出现信息丢失	“一图胜千言”，直接传递视觉/听觉原始细节
输出生成成本	极低（文本生成十分高效）	阶梯式上升（文本 < 语音 < 图像 < 视频）
生成耗时	极快（逐词快速生成，通常只需几秒，可随时中断）	较长（图像/视频生成需数十秒甚至数分钟，不易中途停止）
适用科研场景	文献润色、代码逻辑梳理、理论概念解释	实验仪器界面识别、手写科研档案转录、复杂流程图表分析

4.1.2 跨模态提示词的效率与成本阶梯

多模态大模型在“接收信息”与“创造信息”时的计算资源消耗呈现出显著的非对称性。在科研实践中，向模型输入多模态数据，如上传数张实验设备的参考照片，或一段包含环境噪声的实验录音。这些数据虽然比纯文本输入增加了特征编码的开销，但在现代算力下依然能得到相对快速的处理。然而，一旦大家将指令的意图转向要求模型生成（输出）多模态内容时，其背后的算力负荷、API 调用成本以及所需的等待时间便会呈现出显著的阶梯式增长。

这种生成侧的成本与时间差异，本质上是由不同模态的数据结构与生成机制决定的。纯文本生成是一个高度优化的逐词回归预测过程，计算极为轻量且高效。相比之下，音频生成需要合成连续的物理声波特征；图像生成需要利用扩散模型进行全局的像素级去噪运算；而

视频生成则更是当前 AI 的“算力黑洞”，它不仅要求生成每一帧的高分辨率图像，还必须维持多帧之间的时序物理连贯性。

为了更直观地理解这种阶梯效应，大家可以从科研工程的实际应用视角进行剖析。如果运用提示词让 LLM 仅生成文本形式的文献摘要，那么每调用一万次请求的账单可能仅需几元，且几乎是实时流式响应输出。但如果研究项目需要 LMM 为学术海报生成高质量的插图，甚至生成一段展示三维分子结构的演示视频，底层基础设施的计费模式将从低廉的“按词元（Token）计费”跃升为昂贵的“按张/按秒计费”。此时，单次生成迭代的时间也将从短短几秒拉长到数十秒甚至几分钟。主流大模型各模态生成的平均时间与成本预估参考如表 4-2 所示，量化对比了单次生成任务在耗时与开销上的量级差异。

表 4-2 主流大模型各模态生成的平均时间与成本预估参考

输出模态	生成原理简述	平均响应时间预估	API 调用成本量级预估	中断/迭代灵活性
纯文本	逐个 Token 回归预测	1~3 秒 (百字段落)	极低 (<0.001 元 / 次)	极高 (可实时流式输出, 随时中断)
语音/音频	声学特征映射与波形合成	3~10 秒 (短句语音)	较低 (~0.01 元 / 次)	较高 (可按句分段生成)
高分辨率图像	全局噪声扩散与反向去噪	10~30 秒 (单张图像)	较高 (0.03 - 0.10 元/ 次)	极低 (必须等待全图生成完毕, 无法中途停止)
短视频/动画	时序一致性渲染与多帧去噪	数分钟及以上 (几秒视频)	极高 (> 0.50 元 / 次)	极低 (耗时极长, 试错成本巨大)

基于上述时间与成本的制约，科研人员在使用多模态生成工具时，必须实现提示词策略的根本性转变，即放弃纯文本生成中“无限试错、海量生成后挑选”的习惯。在处理纯文字草稿时，由于成本极低，大家可以随意要求大模型“给出十个不同的推导版本”。但在进行图像或视频生成时，由于试错成本高昂且耗时漫长，大家必须将思考前置。一种高效的科研素养是：在使用昂贵的多模态功能之前，先利用文本大模型作为“草稿本”，反复打磨和确认底层的“描述性提示词”，确保其准确性与丰富度，从而大幅提升多模态生成的一次通过率。这种在有限预算和时间内部署高效生成式应用的全局视野，是跨入多模态时代必备的关键能力。

4.1.3 多模态技术的发展轨迹

在探讨如何将多模态大模型融入科研工作流之前，有必要回顾一下这项技术在过去短短几年间所经历的爆发式进化。在 2022 年前后，早期的多模态模型（如早期的文本生成图像模型）虽然已经能根据提示词生成具备一定视觉连贯性的画面，但在严谨的审视下，它们往

往暴露出大量的“视觉伪影”与逻辑硬伤。在那时，这些工具更多被视为创意领域的“玩具”或灵感发生器，难以胜任要求严苛的科研可视化或学术商业展示。然而，随着底层算法（如扩散模型架构）的快速迭代，现代多模态大模型在精确度、连贯性和细节控制上获得了显著提升，正式迈入了“生产力工具”的行列。

在视觉生成领域的跨越尤为显著，现代模型成功克服了早期长期存在的“结构性失真”与“字符乱码”两大痛点。如果你曾使用过早期的图像生成工具，可能会注意到模型经常在细节处“翻车”：例如生成的人类往往拥有六根手指或扭曲的关节，背景中的直线会出现不合逻辑的断裂，且图像中只要涉及文字，几乎全是无法辨认的外星乱码（甚至连一句简单的“Happy Birthday”都无法正确拼写）。而现代模型不仅大幅修正了基础的物理透视与解剖学结构，更具备了强大的排版与字符渲染能力。在视频生成方面，现代模型也解决了早期视频中背景随时间闪烁、物体在帧与帧之间发生突变的问题，实现了高度的时空连贯性。

与此同时，听觉生成（音频与语音合成）的跨越同样令人瞩目。传统的文本转语音（TTS）技术虽然能准确读出字音，但声音往往扁平、缺乏抑扬顿挫，带有浓重的“机械味”。在处理长篇学术文本时，这种毫无情感起伏的干瘪声音极易让人产生听觉疲劳。而现代 AI 语音克隆与生成技术已经能够深度理解文本的语境，在适当的学术停顿处换气，在强调关键结论时加重语气，甚至能精准模拟出真人的情感起伏，其自然程度在很多盲测中已经让人难以分辨出是由 AI 还是真人发声的。

多模态技术在视觉与听觉维度的全面质量飞跃，进一步拓展了其在科研实践中的赋能价值。对于现代科研工作者而言，这不仅意味着可以通过 AI 大幅降低制作高质量学术海报、实验流程示意图的门槛，也意味着大家可以利用高保真的语音和视频生成技术，将枯燥的论文原稿低成本地转化为引人入胜的“学术播客”或科普短视频，从而以较低成本提升科研成果的传播效率和可理解性。建立对当前 AI 生成质量边界的准确认知，是大家掌握多媒体叙事的关键素养。

4.2 图像理解

掌握了多模态大模型在底层架构与计算成本上的宏观特征后，便可以将其真正投入到具体的科研实战中。科研探索中包含大量高度空间化、结构化和具象化的信息，如果继续沿用传统的纯文本交互方式，往往会面临表达维度的局限。本节将把目光聚焦于多模态交互的“输入端”，深入探讨如何利用人工智能的“视觉感知”能力，有效突破传统文字描述的瓶颈，

实现从“费力解释”到“一图胜千言”的高效信息传递。


4.2.1 突破文字描述的瓶颈

科研人员在与大语言模型交互的日常中，经常会遭遇一种表达上的困境：许多科研概念、系统设计和实验构思是高度空间化和结构化的。例如，当试图解释一个复杂的多级物理实验装置，或者设计了一个包含多重反馈分支的综合实验流程时，如果强制要求用纯文字向 AI 描述这些模块之间的拓扑连线、层级关系或空间位置关联，不仅撰写提示词的过程往往较为繁琐且耗时，大模型也很容易在冗长复杂的文字迷宫中丢失逻辑重点，从而产生理解偏差甚至“幻觉”。

视觉输入的引入在一定程度上缓解了这一局限。当多模态大模型具备了视觉编码能力后，大家将图像直接作为提示词“喂”给模型便成为可能。这种交互方式能够较快速地为 AI 提供极其丰富、密集且未经语言转换折损的原生上下文。科研人员不再需要费尽心思地将二维的结构图“降维”成一维的文字描述，图像直接跨越了语言的沟壑，真正实现了“一图胜千言”的信息传递效率。

让大家通过一个真实的科研场景来直观感受这种效率的飞跃。假设你在实验室的白板上与团队进行了一场头脑风暴，快速画下了一个复杂大模型的领域自适应微调流程图。白板上的字迹有些连笔潦草，甚至当你站在白板前拍照记录时，你的身体还不小心挡住了几个关键的术语缩写。在传统文本交互时代，这张废稿照片很难作为有效的输入素材。但在多模态大模型的支持下，你只需将这张照片上传，并附上一句简单的提示词：“帮我梳理这个算法的逻辑框架，给出结构化的输出。”模型便可能识别出主要模块及其连接关系，并尝试根据上下文推测部分被遮挡内容。视觉输入突破文本瓶颈：从白板草图到算法逻辑提取如图 4-3 所示。可以看出，复杂的算法拓扑图如果用文本进行描述，可能需要数百字的晦涩长句，而通过多模态大模型，极大地拓宽了科研人员将“零碎灵感”转化为“数字资产”的通道。

“帮我梳理这个算法的逻辑框架，给出结构化输出。”



“该算法遵循‘输入—处理—理解—输出’的基本逻辑流程。”

输入阶段：首先接收用户输入的自然语言文本，作为整个处理流程的起点。

处理阶段：对输入文本进行预处理，包括文本清洗、规范化等操作，以消除噪声并统一数据格式。

理解阶段：……”

图 4-3 视觉输入突破文本瓶颈：从白板草图到算法逻辑提取

这种从纯文本到多模态的跨越，也要求科研工作者的思维习惯随之延伸。在多模态时代，“提示工程”不再仅仅局限于“如何用文字把指令说清楚”，更演变成为一种广义的“视觉工程”。这要求大家在日常科研中培养出新的直觉：善于利用镜头建立高密度的上下文锚点。无论是记录团队讨论的密集便利贴、手写推导的复杂公式稿，还是实验仪器上突然闪现的异常报错界面，将其拍照作为提示词的输入部分，从而更充分地利用多模态模型的视觉信息处理能力。这不仅能显著降低学术表达的摩擦力，更能让大家将精力真正聚焦于科研创新本身。

4.2.2 视觉理解的典型场景

多模态大模型的视觉理解能力，早已跨越了传统的“图像分类”（即简单认出图中物品的标签）阶段，进化到了高级的“视觉推理”（即结合人类常识和复杂指令，对图像内的元素进行逻辑处理与计算）。在科研与学术的日常工作流中，这种能力可以应用于多种工作场景，帮助大家将繁杂的视觉信息快速转化为结构化的数据。

第一个典型场景是对复杂单据与非结构化表格的提取与计算。现代科研项目往往高度依赖各类数字化工具与设备。科研人员在管理项目经费时，经常会收到包含密集数据的账单或采购发票，例如利用云端算力平台进行大规模数据处理时产生的周期性计费流水，或者是采购多项试剂耗材的明细清单。面对这些长篇累牍的非结构化账单图片，你可以直接截屏发送给多模态大模型，并下达指令：“列出本月账单中用于算力租赁的具体费用明细，并计算其占总费用的比例。”模型可以辅助完成光学字符识别（OCR），表格结构解析和初步计算，但涉及经费核算、实验数据和关键数值时，相关结果应与原始材料进行人工核对。这种应用方式在保障严谨性的前提下，有助于减轻科研经费核算与资源管理的常规工作负担。

第二个场景是手写科研手稿与历史档案的数字化。无论是在实验室里随手记下的连笔实

验参数、快速推导公式的白板草稿，还是人文学者在整理历史文献时面对的古老手写信件与档案，多模态大模型都能展现出较高的识别容错率。过去，要将这些字迹潦草的纸质资料转化为可检索的电子文本是一项耗时巨大的工程。而现在，由于大模型具备强大的自然语言上下文预测能力，即使遇到墨迹模糊、极度潦草甚至带有涂鸦修改的字迹，它也能“顺藤摸瓜”地推测出完整的语义。

多模态大模型在手写科研笔记数字化中的应用如图 4-4 所示，手写连笔笔记在传统 OCR 软件中往往面临极高的识别错误率，而多模态大模型凭借其语境推断能力，能够跨越笔迹的障碍，将“死”的照片瞬间转化为“活”的数字文本，大幅加速了科研原始数据的数字化进程。




图 4-4 多模态大模型在手写科研笔记数字化中的应用

大家了解了大模型在图像理解强大能力的时候，必须清醒地认识到其现阶段的能力边界。当前的大模型在观察图像时，往往像是在“透过一面轻微模糊的透镜”审视世界，其视觉感知带有明显的“粗粒度”特征。如果被识别的物体具有极其独特全局视觉特征，模型能给出较为完整的描述。但当面对细节特征极为相似的物体时，模型往往会陷入混淆。在日常生活中，如果让它区分一头大象和一只猫，它通常能迅速识别；但如果让它分辨两款仅仅在车灯边角处有细微差别的汽车型号，或者让它从照片中精准区分一只“哈士奇”和一只外形极为相近的“阿拉斯加雪橇犬”，它很可能会给出一段看似高度自信、实则谬以千里的错误答案。多模态大模型的“粗粒度”视觉感知与相似物混淆现象如图 4-5 所示，多模态大模型的视觉感知机制类似于“透过轻微模糊的透镜”观察图像。在面对形态极度相似的日常事物时，这种“粗粒度”特征会导致模型丢失关键的局部细节，进而产生“高度自信的错误判断”。



图 4-5：多模态大模型的“粗粒度”视觉感知与相似物混淆现象

因此，在将多模态大模型融入科研工作时，大家需要建立合理的预期与严谨的核查机制。它可以作为灵感整理和数据初步加工的辅助工具，但在高风险、高精度的科学鉴定任务中，其输出结果绝不能被盲目信任，尤其是对细粒度图像差异的判断以及关键数值的读取。在将其结果写入正式报告或发表论文之前，应结合原始图像、实验记录和领域知识进行必要的人工复核。这一严谨的工作闭环，就能在有效规避学术错误风险的同时，充分享受 LMM 带来的效率提升。

4.2.3 多图协同与复杂上下文归纳

虽然单张图片的输入能够在一定程度上缓解文字描述复杂视觉信息的困难，但在真实的科研工作流中，信息往往是高度碎片化且分布在多个不同的视觉载体上的。例如，在一次科研项目立项或课题组组会讨论中，核心的理论逻辑可能被画在白板上，细碎的待办事项被写在多张便利贴上，而关键的对比数据则可能散落在几张打印出来的图表文献上。单纯依赖一张照片根本无法涵盖整个讨论的全貌，这就引出了多模态大模型另一项重要功能：“多图输入与协同分析”。

多模态大模型处理多图输入，绝不仅仅是按顺序孤立地识别每一张图片里的文字或物体，而是能够在统一的跨模态语义空间中，寻找并建立多张图片之间的内在逻辑关联。它就像一位经验丰富的科研助理，能够敏锐地分辨出哪张图是起支撑作用的“主干”，哪张图是补充说明的“分支细节”，从而将散落的视觉碎片无缝拼接成一个完整的、逻辑严密的上下文背景。

这里，以科研团队普遍经历的头脑风暴会议为例。假设你的课题组刚刚结束了一场关于新项目攻关的激烈研讨。此时，你只需掏出手机拍下三张照片：一张画满整体研究架构的白板照片、一张贴满各成员具体任务的便利贴墙照片，以及一张散落在桌面上、带有指导老师手写批注的往期实验折线图。将这三张图同时上传给多模态大模型，并配以明确的提示词：“请根据这三张会议现场图，总结我们今天讨论的核心研究框架，并生成一份包含具体分工与时间节点的后继行动计划表格。”模型可以分别提取每张图的信息，并尝试进行深度的交叉比对，最终输出一份高度结构化的会议纪要。多图协同输入：从碎片化会议现场到结构化行动计划如图 4-6 所示，通过多图协同输入，大模型能够充当高效的“会议助理”或“知识整理员”。它不仅分别识别了白板架构、便利贴任务和打印图表，还能交叉比对这些信息，进而辅助生成一份结构化的项目执行计划草稿，从而减少部分会后整理工作。



图 4-6 多图协同输入：从碎片化会议现场到结构化行动计划

为了最大化利用这种多图协同推理的能力，科研人员在使用“多图提示词”时应当掌握几个实践技巧：

- (1) 为图片建立明确索引：在文字提示词中明确指出“图 1 是整体架构，图 2 是任务分工，图 3 是参考数据”，这能显著降低大模型在复杂关联中的认知负担，防止信息错位。
- (2) 明确输出格式：可以要求模型将交叉归纳的结果以 Markdown 表格、结构化大纲或特定代码片段的形式输出。这样一来，生成的结果经过核对和整理后，可以复制到知识管理软件或协作写作平台中，或导入 Overleaf 等协作撰稿工具中，实现数字资产的快速流转。
- (3) 保持人工复核的底线：在进行多图交叉推理时，大模型偶尔也会出现“张冠李戴”的幻觉。例如，将图 2 中的某项子任务错误地归属到了图 1 的某个无关模块下。因此，生成后的快速交叉比对和人工校对，依然是保障生成式人工智能在科研实处落地的必备素养。

4.3 图像生成

前一节详细探讨了多模态大模型在“输入端”的视觉感知能力，展示了其如何通过“直视”图表来化解复杂结构化信息的输入难题。然而，跨模态技术的价值不仅在于“理解”，更在于“创造”。当科研工作流进入到成果展示、概念可视化或学术海报制作阶段时，如何将脑海中抽象的实验构思初步转化为具有参考价值的视觉配图，便成了新的挑战。本节将视线正式转向多模态交互的“输出端”图像生成技术。通过深度剖析图像大模型独特的底层显影机制与交互特征，本节将系统梳理出一套较为有效的视觉提示词撰写范式，旨在帮助研究生更好的利用 LMM，实现学术构想向专业级视觉表达的高效转化。

4.3.1 交互体验的转变

前面，从算力成本与生成耗时的宏观角度，剖析了 LLM 与 LMM 的阶梯式差异。当大家把视角拉回具体的科研制图操作界面时，会发现这种底层技术的不同，给用户交互体验带来了明显变化。习惯了使用大语言模型撰写论文的科研人员，往往会带有“线性思维”的惯性：发现 AI 写的第二段偏离了方向，可以随时点击“停止”，并要求它“仅修改第二段的措辞”。文本生成的体验是透明、可控且允许局部“修修补补”的。

然而，在初次接触 Midjourney、DALL-E 3，或是国内的 LMM（如字节跳动的即梦、快手的可灵等）时，这种思维惯性可能导致一定的使用困难。图像模型并不是像人类画师那样先勾勒轮廓，也不是像打印机那样逐个像素地拼接。它的交互体验更像是在开启一个“盲盒”，感官体验类似于一张拍立得相纸的显影过程。在几十秒的等待中，画面是一次性全局生成的，通常整体从高度模糊逐渐变得清晰，或者直接弹出全貌。这种“全局同步演进”的机制带来了两个致命的实操痛点：

（1）不可中断性：文本生成可以随时喊停，但图像生成往往没有提前停止的选项。如果你强行打断，得到的只能是一张布满噪点的废图，而非一张“画了一半的线稿”。

（2）受限的迭代能力：文本可以随意进行局部的“修修补补”，而图像的局部微调往往会触发“蝴蝶效应”，导致整张图的随机重绘。这极大地限制了大家在制图时的迭代试错能力。文本与图像大模型在用户操作体验上的核心差异如表 4-3 所示，这种“要么全有、要么全无”的显影特性，彻底改变了大家与 AI 的博弈策略。

正因如此，图像生成要求大家将“思考前置”。在按下回车键之前，就必须在脑海中构建好完整的画面，并用清晰的语言将其转化为指令。那么，究竟是什么算法导致了图像模型

这种“牵一发而动全身”的特性？为了在后续写出高命中率的提示词，大家需要先拨开它底层的技术迷雾——扩散模型。

表 4-3 文本与图像大模型在用户操作体验上的核心差异

比较维度	文本生成交互体验	图像生成交互体验
中途中断 后果	可保留：已生成的部分依然是有意义的文字， 可直接使用。	不可用：强行中断只能得到布满噪点的废图。
局部修改 难度	极低：可随意指定修改某一段落或特定词汇， 不影响上下文。	极高（蝴蝶效应）：微调局部细节通常会触发整 张图的随机重绘。
用户策略 要求	允许“边想边写”，通过对话逐步引导模型逼 近目标。	要求“思考前置”，必须在一次性提示词中敲定 所有视觉细节。

4.3.2 扩散模型

上一节提到，图像大模型的交互体验类似于“拍立得显影”和“开盲盒”。产生这种独特体验的底层技术黑箱，正是当前统治整个图像生成领域的重要技术：扩散模型。可以说，正是扩散模型的成熟，为图像生成技术的发展提供了新的技术路径。作为研究生，大家或许不必深入推导其背后的数学公式，但有必要了解其基本运行机制，以便更合理地使用和评价图像生成模型。

理解扩散模型，大家需要一种逆向思维：从“破坏”中学习“创造”。先来看看扩散模型最初是如何被训练的，这一过程在学术上称为“前向扩散”。想象一下，你的手里有一张极其清晰的“一只金毛小狗坐在草坪上”的高清照片。现在，算法开始每次向这张照片上撒一把极其微小的“沙子（随机噪点）”。随着“撒沙子”的动作重复几十次甚至上百次，这张原本清晰的小狗照片会变得越来越模糊，直到最终完全变成了一堆毫无规律、密密麻麻的杂乱沙点，其视觉效果就如同老式电视机无信号时的雪花屏，即“纯噪声图”。AI 的训练过程，就是在旁边默默观察并记录下这只小狗是如何一步步被“沙子”吞没的。通过观察数以亿计的图像被“破坏”的完整生命周期，大模型学会了一个核心能力：“噪声是如何一步步掩盖有效图像特征的”。

既然学会了破坏，那么创造的过程也就顺理成章了。当你在网页输入框中敲下提示词并按下回车键时，AI 画布的起点绝不是一张白纸，而是一张完全由随机噪点组成的“纯噪声图”。接下来进入反向扩散或去噪生成过程。在此时，你输入的提示词就充当了“引路灯”。

AI 就像一个拥有透视眼的雕塑家，在提示词的精确引导下，努力在混沌的噪点中分辨出“小狗的耳朵”、“毛发的纹理”以及“草地的背景”轮廓，并反向执行它学到的去噪规律，一步一步地把多余的“沙子”剥离出去。随着数十步的“去噪”迭代计算，画面整体便从一团模糊渐渐收敛为清晰的物理结构。

这一机制可以帮助解释上一节提到的生成特点：如果你在中途（比如进度条 50% 时）强行停止生成，得到的只能是一张满是雪花点的废图，因为画面上的“沙子”还没有被算法完全清理干净。扩散模型的反向去噪过程（以生成小狗照片为例）如图 4-7 所示，扩散模型就像是一个在浓雾中寻找信号的雷达。在反向扩散过程中，输入的文本提示词充当了“引路灯”，指引模型在无数种去噪可能性中，逐步生成用户想要的特定图像上。




图 4-7 扩散模型的反向去噪过程（以生成小狗照片为例）

从这种底层原理中，大家还能得到一个重要的实操启示：认清并控制随机性。正因为每次生成任务的起点都是一张“完全随机的纯噪声图”（即算法中的随机种子 Seed 不同），导致噪点“沙子”的初始分布状态永远不会重复。这就解释了为什么即使你输入了完全相同的提示词，每次生成的小狗在姿态、毛发斑纹或背景草地的分布上也会有所不同。

扩散模型本质上是在茫茫的数据海洋中玩一个高维的“概率游戏”。因此，为了尽可能控制这种发散的随机性，逼近大家脑海中真正需要的精确科研或工程配图，不宜像使用大语言模型闲聊那样给它一句随意的口语指令，而应尽量提供精准和结构化的提示词，去强制收敛并约束它的去噪路径。那么，怎样才能写出这种具有强约束力的专业视觉指令呢？这正是下一节要探讨的核心技巧。

4.3.3 图像提示词的撰写范式

在使用图像生成大模型时，初学者最容易陷入的误区就是试图用日常聊天的思维去书写提示词。大家往往会写出一段带有复杂语法的口语化长句，例如：“请帮我画一张图，图里面有一只小猫，它正在沙发上睡觉，窗外最好有阳光照进来，看起来要很温馨……”

必须明确的是，扩散模型并不具备人类那种理解长篇语法逻辑和复杂从句的能力。对于模型而言，复杂的连接词和语气词往往是“噪音”，不仅起不到引导作用，反而会干扰模型对关键视觉特征的捕捉。高质量的图像提示词更像是一组“高度结构化的标签清单”，通过有序堆叠具体的视觉要素，帮助模型围绕明确的视觉要素进行生成，让其生成的结果与你的构思高度对齐。

一套成熟的图像提示词撰写范式，通常由三个核心维度构成：

（1）主体/角色：这是画面的灵魂。必须给出材质、颜色、形态等物理细节。例如，不要只说“一杯咖啡”，而要明确描述为“一个白色的陶瓷马克杯，里面装满了带有树叶拉花的热拿铁”。

（2）场景/环境：主体被安放在怎样的空间中？是波士顿风格的复古红砖公寓内部、喧闹的城市街头，还是清晨宁静的绿茵草坪？环境决定了画面的空间感与叙事背景。

（3）情绪/氛围：画面要传达出怎样的观感？是“温馨恬静的”、“充满活力的”，还是“冷峻深邃的”？这些感性词汇会显著影响AI调用的色彩分布与明暗对比逻辑。

很多人常感到“写不出好图”，其实是因为缺乏专业的艺术词汇储备。为了弥补这一短板，大家需要主动掌握一套“视觉修饰词”。这就好比为你的日常画面配备了“滤镜引擎”：仅仅输入“一个打球的人”只会得到一张平庸的简笔画或毫无质感的配图；但如果你加上“写实摄影”、“黄金时刻光影”或“35 毫米镜头”，画面的构图、光影和质感通常会更加明确。

结构化图像提示词的撰写公式与生活范例如表 4-4 所示，总结了一套在主流多模态大模型中具有参考价值的“视觉提示词公式”。按照该结构补充画面要素，有助于提高提示词的清晰度，并可能改善生成结果。

掌握了这套结构化公式后，你就不再是简单地向 AI “许愿”，而是在像一位专业的摄影指导或美术导演一样，通过精准的视觉语言指令，一步步引导模型在无数种去噪路径中，精确捕捉到你脑海中那个兼具逻辑与审美的图像目标。纸上谈兵终觉浅，让大家通过图 4-8 来直观感受一下提示词的“魔力”。左图使用的是大家在日常聊天中习惯的“普通口语指

令”，而右图则严格套用了表 4-4 中的“结构化专业指令”。可以看出，仅仅是增加了环境细节、镜头语言和光影渲染词汇，AI 生成的图像质量就发生了从“平庸简笔画”到“商业级摄影大片”的惊人蜕变。

表 4-4 结构化图像提示词的撰写公式与生活范例

公式维度	核心作用	典型视觉词汇库(词典示例)	生活化应用示例
1. 核心主体	锚定焦点，设定对象物理细节	陶瓷茶杯、毛茸茸的金毛犬、木质吉他、挥杆的高尔夫球手	[主体]: 一位穿着白色运动 Polo 衫的高尔夫球手，正在全力挥杆击球，动作充满爆发力...
2. 场景与视角	设定空间背景与镜头语言	微距视角、复古红砖墙背景、鸟瞰视角	[场景]: 站在阳光明媚、绿草如茵的开阔球场上，背景是平静的湖面与远山，低角度仰拍视角...
3. 媒介与风格	决定最终呈现的艺术载体形式	水彩风格、拍立得胶片风、3D 卡通、写实摄影	[风格]: 高动态范围的写实体育摄影风格...
4. 光影与渲染	提升专业质感与分辨率	电影级光影、黄金时刻夕阳、丁达尔效应、8K	[光影]: 傍晚的黄金时刻逆光，草地上带有长长的阴影，超高清晰度，8K 分辨率。



图 4-8 普通提示词与结构化专业提示词的生成质量对比

4.3.4 借助文本大模型优化图像提示词

科研人员在设计学术图表时，往往面临着这样一个核心矛盾：研究者通常较熟悉自己的研究概念和核心信息（如“领域自适应漏斗”、“语义保真事后水印”、“跨模态对齐机制”），但往往难以将其转化为精准的视觉描述词汇。如果仅输入这些枯燥的学术名词，AI

的生成结果往往是平庸无奇、缺乏专业质感的。此时，需要引入一个强大的“翻译官”——文本大模型，通过“以 AI 治 AI”的方式，构建属于科研人员的视觉描述力。

1. 让文本大模型“代笔”专业提示词

最直接的路径是利用文本大模型作为你的“专属科学插画师助理”。不要直接在图像生成框中纠结词汇，而是先向文本大模型下达明确的指令。

操作指引：采用“角色扮演法”，向文本模型输入：“请作为一名资深的科学插画师，为[插入你的科研概念]写一段用于图像生成模型的英文提示词。要求包含具体的材质细节、光影效果、镜头角度以及艺术风格（如极简主义、科技感等）。请给出三个不同视觉风格的版本。”

核心收益： 文本大模型拥有海量的艺术词汇库，它会将你模糊的“想要一张图”转化为诸如 “Octane render, cinematic lighting, hyper-realistic, iridescent material” 等高质量的视觉描述。这能帮你瞬间跨越词汇障碍，生成更符合学术配图需求、包含主体、风格、光影和构图信息的提示词。

2. 通过“喂图”实现视觉语言的逆向解构

当你看到顶级期刊（如 Nature 或 Science）中某张心仪的配图时，与其感叹“为什么我画不出这种感觉”，不如将其作为反向工程的素材。

操作指引： 将那张图截屏并上传给支持视觉识别的大模型。

提问范式：“作为一个专业的视觉艺术家，请从光影对比、配色方案、构图角度、材质呈现以及艺术流派（如未来主义、极简主义）等方面，详细拆解这张图的视觉组成，并根据你的分析，为我反推一套可以复刻这种风格的图像生成提示词。”

核心收益： 这种“逆向工程”能让你迅速扩充个人的“视觉词典”，并建立属于你研究领域的专属视觉风格库，精准复刻行业顶尖审美。

面对海量的视觉表达方式，大家无需死记硬背艺术词汇，而是应学会利用多模态模型的“互补性”。借助文本/多模态模型优化图像生成提示词的实操路径如表 4-5 所示，归纳了科研中常用的“以 AI 治 AI”的提示词优化路径。

表 4-5 借助文本/多模态模型优化图像生成提示词的实操路径

优化手段	输入端（你的输入）	输出端（AI 的产出）	核心收益
文本代笔	具体的科研概念(如“语义保真事后水印”)	结构化的英文视觉描述（包含主体、光影、渲染器、画风）	快速跨越词汇障碍，生成具备专业质感的构图描述。
视觉逆向工程	优秀的学术配图截屏 + “描述并复刻此风格”	详细的视觉艺术词汇分析与对应的提示词建议	建立属于自己的学术领域视觉风格库，精准复刻行业顶尖审美。

3. 迭代思维：提示词是起点而非终点

即使有了文本大模型的强力辅助，大家也必须保持一种“敏捷迭代”的工作流思维。就像在协同文档平台中反复推敲一段核心文字一样，优秀的图像提示词也是改出来的。千万不要期待一次生成就能完美契合脑海中的所有细节。

标准的工作流应该是闭环的：

初次尝试：使用文本大模型“代笔”生成的提示词，进行第一次图像生成；

视觉反馈：仔细观察生成的图像，找出偏离预期的部分（例如：“画面整体质感很棒，但光线太暗了，而且背景的元素过于杂乱抢戏”）；

反馈修正：回到文本大模型，把你的观察告诉它：“刚才生成的提示词效果不错，但画面太暗且背景杂乱。请帮我修改提示词，增加全局照明，并把背景改为纯色极简风格，突出主体。”

最终成图：拿着优化后的新提示词，再次进行图像生成。

通过这种“生成——观察——对话微调——再生成”的严谨迭代过程，你不仅能收获理想的视觉配图，更能在这个过程中，深刻理解并掌握“提示词变量”与“最终画面效果”之间的对应关系。掌握了这一套方法论，你就真正从一个“只会向 AI 许愿的新手”，进阶成了“能够精准驾驭 AI 画笔的导演”。

4.3.5 生成图像的常见瑕疵

虽然扩散模型在视觉内容生成方面表现出较强的图像合成能力，但在惊叹之余，必须清醒地认识到，其底层的概率预测逻辑决定了它天生具有生成“视觉幻觉”的倾向。对于创作者而言，能敏锐地识别并修复这些潜在的视觉瑕疵，往往比盲目生成一张精美图片更具实际价值。应当始终秉持一个原则：AI 生成的图像更适合作为“视觉草图”或“参考素材”，正式使用前仍需人工审查和必要修改。

在当前的图像生成场景中，最常遇到的挑战集中在以下三个领域：

（1）结构违背物理常识：扩散模型知道事物“看起来”是什么样，但并不理解事物背后的“物理法则”。这导致它在绘制复杂结构时经常犯常识性错误。例如，画一辆自行车时，踏板可能根本没有连接到链条上；画人物时，手部经常出现多根手指或关节扭曲；在绘制机械齿轮时，齿与齿之间可能完全无法咬合。

（2）文本渲染乱码：尽管模型在自然语言处理方面能力卓绝，但在图像中“画出”正

确的文字依然是一个巨大的挑战。当尝试生成带有文字的海报、流程图表或路标时，图像中的英文字母往往会出现拼写错位，甚至显示为毫无意义的“外星乱码”。

(3) 跨图连贯性失效： 这是在制作连续叙事画面（如分镜脚本或步骤说明图）时最大的痛点。当试图生成一组连续的动作时，模型往往难以维持主体特征的高度一致性。例如，上一张图里的主角穿着带领带的西装，在下一张同场景的图中，领带可能莫名其妙地消失了，或者原本圆形的道具变成了方形。

针对图像生成过程中的不确定性，当前技术已发展出多种可控生成方法，实现了由高度随机生成向基于条件约束的可控生成的转变：

控制网络：用于增强结构约束的技术方法。通过向 AI 输入一张简单的线稿、骨骼姿态图或深度图，可以在一定程度上约束 AI 在指定的轮廓骨架下进行生成。这就好比给 AI 戴上了“紧箍咒”，确保其输出的物体结构符合物理逻辑。

种子值固定与参考图： 每一个随机种子值对应一种确定的初始噪点分布。在制作连续画面时，通过固定种子值，并配合现代模型提供的“角色参考”或“风格参考”功能，可以有效锚定主体特征，确保不同画面之间的视觉连贯性。

局部重绘：当图像整体效果基本符合预期，只有文字拼写错误或某个局部零件畸变时，无需推翻重来。只需在操作界面上涂抹错误区域，输入针对性的修复提示词，引导模型仅对该部分进行重新计算与修复，极大地节省了生成成本。面对 AI 固有的视觉瑕疵，成熟的创作流应当是“先生成底图，再精细干预”。图像生成缺陷分类与实操修复指南如表 4-6 所示。

表 4-6 图像生成缺陷分类与实操修复指南

常见瑕疵类型	具体表现示例	修复与规避方案
结构逻辑扭曲	机械零件无法闭合、人物手部出现多余手指或畸变	采用 ControlNet 技术，利用线稿、人体骨架图或深度图作为结构约束。
文本渲染乱码	图像中的店招、海报专有名词拼写错位或不可读	后期干预法：要求 AI 生成无文字的干净底图，随后使用设计软件（如 Photoshop ）手动添加文本。
时空不连贯	多图流程演示或连环画中，核心角色外观频繁变异	使用相同的 Seed 值，或采用“角色参考”功能强制锚定主体特征。
像素噪点与模糊	图像边缘细节模糊、色彩衔接生硬或分辨率不足	利用后期超分模型提升分辨率，并配合局部重绘（修补瑕疵区域）。

最后，需要强调人工核验机制的必要性。图像生成工具本质上是辅助科研表达的手段。AI 生成的图像在用于演示、出版或正式发表前，应进行人工校对；特别是涉及数据、结构、文字标签和专业符号的图像，还应与原始资料和学科规范进行严格核验。通过建立严谨的人机协作流程，研究人员能够在有效利用 AI 技术优势的同时，确保专业内容输出的严谨性与准确性。

4.4 音视频大模型

上一节讲了如何利用 AI 构思并画出高质量的静态科研配图。但现实的科学世界是动态变化的，不管是微观细胞的生长过程、流体的混合轨迹，还是复杂的设备操作步骤，仅靠几张“不会动”的图片往往很难跟别人解释清楚。这就需要引入更强大的多模态工具——音视频生成大模型。本节将重点讲解如何让死板的图表“动起来”变成演示动画，以及如何利用 AI 语音合成技术为复杂理论提供语音讲解。掌握了这些技巧，就能在一定程度上拓展科研成果的展示形式，把枯燥的科研成果转化成极具吸引力的视听体验。

4.4.1 语音合成

回顾仅仅几年前的文本转语音技术，人们脑海中往往会浮现出一种极其刻板的印象：发音虽然字正腔圆，但声音扁平、僵硬，缺乏人类说话时自然的情感起伏与重音停顿，带有浓重的“机械味”或“AI 味”。这种毫无感情的“念稿机”在处理短促的导航语音时或许勉强够用，但如果用来朗读长篇的学术文献或进行科普解说，极易让听众产生听觉疲劳。

然而，现代音频大模型在语音自然度、音质和情感表达方面已有明显提升。得益于深度学习架构的突破，如今的 AI 语音不仅在音质上达到了录音室级别的高保真标准，更能在一定程度上模拟出人类在讲话时的微小细节——包括自然的呼吸声、换气时的气口、甚至是特定情绪下的语调变化，让合成声音的“机器味”大幅降低。当前，业界已经涌现出诸多高质量语音生成与语音克隆模型。例如，国际顶尖的 ElevenLabs 能够细腻地捕捉文本语境并演绎出极具张力的情感，只需几秒钟样本即可实现高保真的声音克隆；OpenAI 的高级语音模型则以极低的延迟和极致的对话自然度重塑了交互体验。而在国内开源生态中，同样有如 ChatTTS 这类针对对话场景深度优化的现象级模型，能极其逼真地还原人类交谈时的笑声与语气词；以及阿里通义实验室的 CosyVoice，在跨语言零样本声音克隆上展现出强大的实力。这些现代语音引擎的成熟，为枯燥的科研图文低成本转化为引人入胜的“学术播客”提供了坚实的技术基座。

伴随高保真音质而来的，是个性化语音克隆技术取得了明显进展。过去，如果想要合成一个专属的定制声音，需要在专业的录音棚中录制长达几十个小时、包含数万句语料的高质量音频。而现在的音频大模型支持“零样本”或极少样本的声音克隆。这意味着，科研人员只需上传一段自己过去在讲台上几分钟的干净讲课录音，模型就能在短短几秒钟内，克隆出与你音色、发音习惯乃至口音基本一致的专属“数字声音分身”。

这种跨越式的技术进化，在一定程度上缓解科研工作者在学术传播与日常工作中的两大痛点：

其一是学术演讲与课程录制的“无痕修音”。试想一下，当你为了即将到来的国际学术会议，辛苦录制了一段长达 40 分钟的全英文汇报视频后，在后期检查时突然发现中间某个关键的专有名词念错了，或者某句话结巴了。在过去，你往往只能大费周章地重新录制整段视频。而现在，借助支持文本驱动的语音编辑模型，你只需在对应的音频波形处输入正确的文字，AI 就能用你自己的专属声音，无缝替换掉错误的那几秒，真正实现了极低成本的后期“无痕修音”。

其二是论文与专著的“播客化”传播。传统的科研论文往往是枯燥的纯文本，难以触达学术圈之外的受众。借助高保真情感语音，研究者可以一键将长篇的论文原稿或研究亮点转化为引人入胜的“学术播客”或有声读物。这不仅方便了同行在通勤、做实验时“听文献”，也极大地降低了前沿科学知识向大众传播的门槛。传统语音合成与现代语音大模型的学术应用对比如表 4-7 所示。从传统 TTS 到现代语音大模型的进化，不仅是音质的提升，更是从“被动阅读”到“主动表达”的跨越。这些工具为学术成果的多形式传播提供了新的技术手段。

表 4-7 传统语音合成与现代语音大模型的学术应用对比

维度	传统语音合成	现代语音大模型	对科研/学术的价值赋能
音色与情感	声音扁平、机械，语调单一	饱含情感，支持调整情绪（如激动、严肃），带有自然呼吸声	能生成极具感染力的学术演讲旁白或科普视频配音，告别枯燥乏味。
语音定制成本	需在专业录音棚录制数万句语料训练	仅需几分钟个人音频片段即可完成高精度克隆	学者可轻松拥有自己的“数字声音分身”，随时随地合成讲稿。
后期修正能力	难以对原有录音进行无缝的局部修改替换	支持文本驱动的局部音频重生（无痕修音）	极大降低学术会议录播、网课录制时的重录与试错成本。

当然，尽管现代语音大模型已经非常聪明，但在处理复杂的科研文本时，仍需要掌握一些简单的“音频提示词”技巧来进行引导。例如，当文本中包含晦涩的生僻字、多音字或特殊的化学式时，可以直接在提示词中使用拼音或音标进行强制注释，引导 AI 正确朗读生僻字、多音字和专业术语。；当需要在学术演讲中强调某个结论时，可以通过在文本中插入破折号（——）或省略号（……）等来强制大模型增加停顿时间。此外，你甚至可以在提示词框中明确设定角色：“请用一位严谨且充满热情的物理学教授的口吻，以中等语速朗读这段文字”，通过这种情境设定，能够更大程度地激发模型的情感表现力，让原本冰冷的学术文字真正地“活”起来。

4.4.2 视频生成

长期以来，科学研究在成果展示上一直面临着一个天然的痛点：真实的科学世界是高度动态的。无论是显微镜下细胞的分裂与凋亡、复杂神经网络中的海量数据流转，还是微流控芯片中的液滴混合，这些过程都充满了时间维度上的演进。然而，受限于传统的学术出版载体，科研人员往往只能用几张静态的二维图片，再加上几根生硬的箭头，来“强行”解释复杂的动态机理。近年来，随着视频生成大模型（如 Runway、Kling、Seedance 等）的快速发展，这种静态图文表达的局限在一定程度上得到缓解。视频大模型为科学可视化引入了关键的“时间维度”，让原本只能在研究者脑海中推演的复杂科学机理，得以用直观、连续的动画形式被真实地呈现出来。

在诸多视频生成技术路径中，对科研工作者而言，“图生视频”是一种较为实用的技术路径。在处理严谨的科研图表中，单纯依赖“文本生视频”往往难以精准控制核心主体的物理轮廓和空间结构。但如果将其与上一节学到的图像生成技术结合，就能形成一个完美的闭环：科研人员可以先利用图像大模型（或自行手绘、通过专业工具导出）生成或制作一张结构较清晰的“静态概念图”或“算法架构图”，然后将其作为起始帧输入给视频大模型，并下达明确的运动指令（例如：“让图中的发光数据流沿着神经网络的节点依次向前推进”）。这种方式赋予了静态科研配图以生命，能以极低的成本将枯燥的图文摘要转化为引人入胜的动态演示。

这种动态视频的加入，对日常的学术交流与科研传播堪称一种“降维打击”。首先是在学术会议场景中，当你站在国际顶会的演讲台上，试图解释一项复杂的底层机制。比如，动态展示“靶向药物分子”是如何在血液中穿梭并精准嵌入癌细胞受体的。用一段仅仅 10 秒钟的 AI 生成概念动画作为开场，其吸睛效果和知识传递效率将远远超过十几张密密麻麻的 PPT 幻灯片。其次，在大众科普或重大科研基金项目的申请答辩中，评委或受众往往并非你所在细分领域的同行。此时，一段由 AI 生成的高保真概念视频有助于降低非专业受众理解复杂概念的门槛，将晦涩的数学公式和抽象的理论转化为直观的视觉冲击，提升你研究成果的说服力与社会影响力。静态学术成果向动态视频转化的 AI 工作流如图 4-9 所示。通过“文本生成图像”再叠加“图像生成视频”的组合拳，研究者即使不熟悉专业 3D 动画制作软件（如 Maya、Blender），也可以借助视频生成工具制作初步动态演示素材，将一篇静态的学术论文转化为一段生动的概念演示视频，极大提升了成果的传播效能。

尽管视频生成技术在视觉表现方面已有明显进展，但科研人员在应用时仍需清醒地认识

到它目前的局限性。当前视频大模型的工作原理，说白了就是在玩一场“猜像素”的概率游戏，它只是死记硬背了海量画面变化的规律，但压根不懂现实世界的物理法则。正因如此，AI 视频很容易产生“物理幻觉”。比如，它生成的流体动画看起来很逼真，但根本经不起流体力学方程的推敲；它画出来的两车相撞，看起来轻飘飘的，完全没有真实的质量与惯性，有时甚至会出现苹果往天上飞这种违背常识的荒谬画面。这就划定了一道不可逾越的红线：目前的 AI 视频生成只能作为“科学概念的视觉动画演示”，不应替代那些基于严密数学公式的“科学仿真与物理计算”。




图 4-9 静态学术成果向动态视频转化的 AI workflow

4.5 本章实训

打破单一文字的限制，综合运用多模态大模型的看图、画图、配音和生成视频能力，将一个基础的科学常识（以“植物的光合作用”为例），从零开始制作成一段带语音解说的生动科普小短片。通过这个过程，彻底掌握从“静态图文”到“动态视听”的 AI workflow。

演练一：让 AI 帮你看懂图表（视觉解析）

操作：在网上找一张结构复杂的“植物光合作用原理图”（包含阳光、叶绿体、二氧化碳、氧气等元素），如图 4-10 所示，将其上传给具备视觉能力的大模型（如 DeepSeek）。




图 4-10 植物光合作用原理图

输入指令：“请仔细观察这张图，用最通俗的大白话解释光合作用的三个核心步骤。如果要在课堂上给中学生讲这张图，我应该重点指出图里的哪几个关键箭头？”

核心目的：体验 AI 如何迅速拆解密集的结构化图像信息，为你提炼出关键的讲解思路。

演练二：指挥 AI 画出高质量概念图（图像生成）

操作：抛弃简陋的网络配图，利用前面学到的“四维结构化公式”（主体 + 场景 + 风格 + 光影），自己生成一张极具视觉冲击力的底图。

输入指令：

[主体]：一片放大的绿色植物叶片，表面正在吸收金色的阳光粒子和蓝色的水分子。

[场景]：微观视角，叶片内部的细胞结构隐约可见。

[风格]：3D 科学概念插画，虚幻引擎渲染。

[光影]：清晨的阳光逆光照射，背景带有梦幻的光学虚化（景深效果），8K 分辨率。

核心目的：告别只会发大白话指令的“抽盲盒”状态，用专业的结构化提示词精准控制画面的质感与细节。

演练三：让画面动起来（视频生成）

操作：将步骤二中生成的高质量静态叶片图，上传到视频生成工具（如 Seedance 或 Kling）。

输入动态指令：“金色的阳光粒子像流星一样缓缓飞入绿色的叶片表面，同时叶片边缘有极其微小的氧气气泡向上升起。”

核心目的：体验“图生视频”的奇妙转化，掌握如何用简单的文字指令控制静态元素的物理运动。

演练四：生成专业级配音（音频生成）

操作： 写一段 50 字左右的解说词（例如：“光合作用，是大自然最神奇的魔术。植物就像一台精密的太阳能机器，把光转化为生命的能量.....”）。将这段文字输入到现代语音合成工具（如 ChatTTS 或 CosyVoice）中。

音频设置： 选择一个沉稳、有感染力的“纪录片解说员”音色，生成一段高保真的音频。

核心目的： 彻底告别毫无感情的“机器播报”，用带有情绪起伏的专业配音为动态画面注入灵魂。最终将生成的视频和配音组合，即可完成一个极具吸引力的科学演示短片。